



**AKADEMIA GÓRNICZO – HUTNICZA
IM. STANISŁAWA STASZICA W KRAKOWIE
WYDZIAŁ INŻYNIERII MECHANICZNEJ I ROBOTYKI**

**PRACA DYPLOMOWA
magisterska**

**Analiza przydatności sztucznej sieci neuronowej w
ocenie pracy serca**

*Analysis of the usefulness of artificial neural network in heart rate
assessment*

Autor:

Grzegorz Tworek

Kierunek studiów:

Mechanika i Budowa Maszyn

Opiekun pracy:

dr hab. inż. Wiesław Wszolek

.....
podpis

Kraków, rok 2020

OŚWIADCZENIA STUDENTA

Kraków, dniar.

Grzegorz Tworek

.....
Imiona i nazwisko studenta

Mechanika i Budowa Maszyn, 2 stopień, stacjonarne

.....
Kierunek, poziom, forma studiów

Wydział Inżynierii Mechanicznej i Robotyki

.....
Nazwa Wydziału

dr hab. inż. Wiesław Wszółek

.....
Imiona i nazwisko opiekuna pracy dyplomowej

ja niżej podpisany(-a) oświadczam, że:

jako twórca pracy dyplomowej inżynierskiej / licencjackiej / magisterskiej* pt.

.....
Analiza przydatności sztucznej sieci neuronowej w ocenie pracy serca

.....

1. **uprzedzony(-a) o odpowiedzialności karnej** na podstawie art. 115 ust. 1 i 2 ustawy z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (t.j. Dz.U. z 2018 r. poz. 1191, z późn. zm.): „Kto przywłaszcza sobie autorstwo albo wprowadza w błąd co do autorstwa całości lub części cudzego utworu albo artystycznego wykonania, podlega grzywnie, karze ograniczenia wolności albo pozbawienia wolności do lat 3. Tej samej karze podlega, kto rozpowszechnia bez podania nazwiska lub pseudonimu twórcy cudzy utwór w wersji oryginalnej albo w postaci opracowania, artystyczne wykonanie albo publicznie zniekształca taki utwór, artystyczne wykonanie, fonogram, wideogram lub nadanie.”, **a także uprzedzony(-a) o odpowiedzialności dyscyplinarnej** na podstawie art. 307 ust. 1 ustawy z dnia 20 lipca 2018 r. Prawo o szkolnictwie wyższym i nauce (Dz. U. z 2018 r. poz. 1668, z późn. zm.) „Student podlega odpowiedzialności dyscyplinarnej za naruszenie przepisów obowiązujących w uczelni oraz za czyn uchybiający godności studenta.” **niniejszą pracę dyplomową wykonałem(-am) osobiście i samodzielnie i nie korzystałem(-am) ze źródeł innych niż wymienione w pracy;**
2. praca dyplomowa jest wynikiem mojej twórczości i nie narusza praw autorskich innych osób;
3. wersja elektroniczna przedłożonej w wersji papierowej pracy dyplomowej jest wersją ostateczną, która będzie przedstawiona komisji przeprowadzającej egzamin dyplomowy;
4. praca dyplomowa nie zawiera informacji podlegających ochronie na podstawie przepisów o ochronie informacji niejawnych ani nie jest pracą dyplomową, której przedmiot jest objęty tajemnicą prawnie chronioną;
5. []** udzielam nieodpłatnie Akademii Górniczo-Hutniczej im. Stanisława Staszica w Krakowie licencji niewyłącznej, bez ograniczeń czasowych, terytorialnych i ilościowych na udostępnienie mojej pracy dyplomowej w sieci Internet za pośrednictwem Repozytorium AGH.

.....
czytelny podpis studenta

Jednocześnie Uczelnia informuje, że:

1. zgodnie z art. 15a ww. ustawy o prawie autorskim i prawach pokrewnych uczelni przysługuje pierwszeństwo w opublikowaniu pracy dyplomowej studenta. Jeżeli uczelnia nie opublikowała pracy dyplomowej w terminie 6 miesięcy od dnia jej obrony, autor może ją opublikować, chyba że praca jest częścią utworu zbiorowego. Ponadto uczelnia jako podmiot, o którym mowa w art. 7 ust. 1 pkt 1 ustawy z dnia 20 lipca 2018 r. – Prawo o szkolnictwie wyższym i nauce (Dz. U. z 2018 r. poz. 1668, z późn. zm.), może korzystać bez wynagrodzenia i bez konieczności uzyskania zgody autora z utworu stworzonego przez studenta w wyniku wykonywania obowiązków związanych z odbywaniem studiów, udostępniać utwór ministrowi właściwemu do spraw szkolnictwa wyższego i nauki oraz korzystać z utworów znajdujących się w prowadzonych przez niego bazach danych, w celu sprawdzania z wykorzystaniem Jednolitego Systemu Antyplagiatowego. Minister właściwy do spraw szkolnictwa wyższego i nauki może korzystać z prac dyplomowych znajdujących się w prowadzonych przez niego bazach danych w zakresie niezbędnym do zapewnienia prawidłowego utrzymania i rozwoju tych baz oraz współpracujących z nimi systemów informatycznych;
2. w świetle art. 342 ust. 3 pkt 5 i art. 347 ust. 1 ustawy Prawo o szkolnictwie wyższym i nauce minister właściwy do spraw szkolnictwa wyższego i nauki prowadzi bazę danych zwaną repozytorium pisemnych prac dyplomowych, która obejmuje: tytuł i treść pracy dyplomowej; imiona i nazwisko autora pracy dyplomowej; numer PESEL autora pracy dyplomowej, a w przypadku jego braku – numer dokumentu potwierdzającego tożsamość oraz nazwę państwa, które go wydało; imiona i nazwisko promotora pracy dyplomowej, numer PESEL, a w przypadku jego braku – numer dokumentu potwierdzającego tożsamość oraz nazwę państwa, które go wydało; imiona i nazwisko recenzenta pracy dyplomowej, numer PESEL, a w przypadku jego braku – numer dokumentu potwierdzającego tożsamość oraz nazwę państwa, które go wydało; nazwę uczelni; datę zdania egzaminu dyplomowego; kierunek, poziom i profil studiów. Ponadto, zgodnie z art. 347 ust. 2-5 ustawy Prawo o szkolnictwie wyższym i nauce ww. dane wprowadzają do Zintegrowanego Systemu Informacji o Szkolnictwie Wyższym i Nauce POL-on (System POL-on) rektorzy. Dostęp do danych przysługuje promotorowi pracy dyplomowej oraz Polskiej Komisji Akredytacyjnej, a także ministrowi w zakresie niezbędnym do prawidłowego utrzymania i rozwoju repozytorium oraz systemów informatycznych współpracujących z tym repozytorium. Rektor wprowadza treść pracy dyplomowej do repozytorium niezwłocznie po zdaniu przez studenta egzaminu dyplomowego. W repozytorium nie zamieszcza się prac zawierających informacje podlegające ochronie na podstawie przepisów o ochronie informacji niejawnych.

* - niepotrzebne skreślić;

** - należy wpisać TAK w przypadku wyrażenia zgody na udostępnienie pracy dyplomowej, NIE – w przypadku braku zgody; nieuzupełnione pole oznacza brak zgody na udostępnienie pracy.

Akademia Górniczo-Hutnicza im. Stanisława Staszica

Kraków,

Wydział Inżynierii Mechanicznej i Robotyki

Kierunek studiów: Mechanika i Budowa Maszyn

Specjalność: Informatyka w Inżynierii Mechanicznej

Grzegorz Tworek

Imię i nazwisko studenta

Praca dyplomowa magisterska

Analiza przydatności sztucznej sieci neuronowej w ocenie pracy serca

.....

.....

(tytuł pracy)

Opiekun: *dr hab. inż. Wiesław Wszolek*

STRESZCZENIE

Część teoretyczna pracy magisterskiej opisuje wybrane zagadnienia z dziedziny sztucznych sieci neuronowych i elektrokardiografii oraz przykładowe zjawiska możliwe do wykrycia na zapisie Holtera. W części projektowej pracy zaimplementowano sztuczną sieć neuronową w środowisku Matlab, która ma za zadanie rozpoznawać sygnały elektrokardiograficzne i przyporządkowywać je do jednej z trzech grup. Sygnały zostały pobrane z ogólnodostępnej bazy Physionet, a następnie przetworzone do postaci skalogramów w formacie jpg. Przetworzone dane zostały podzielone na dane uczące i testowe i wykorzystane do uczenia sieci. Rezultaty zostały przedstawione dla dwóch sieci neuronowych różniących się ilością danych.

AGH University of Science and Technology

Kraków, the.....

Faculty of Mechanical Engineering and Robotics

Field of Study: Mechanical Engineering.....

Profile/speciality*: Informatics in Mechanical Engineering.....

Grzegorz Tworek.....

(First name and family name of the student)

Master Diploma Thesis

Analysis of the usefulness of artificial neural network in heart rate assessment

.....

.....

(Thesis title)

Supervisor: *dr hab. inż. Wiesław Wszolek*

SUMMARY

The theoretical part of the thesis describes selected issues in the field of artificial neural networks and electrocardiography and examples of phenomena that can be detected on Holter's record. In the design part of the thesis an artificial neural network was implemented in the Matlab environment, which is to recognize electrocardiographic signals and assign them to one of three groups. The signals were downloaded from the publicly available Physionet database and then processed into jpg scalograms. The processed data were divided into teaching data and testing data and used to teach the network. The results were presented for two neural networks differing in amount of data.

Kraków, dnia

**AKADEMIA GÓRNICZO-HUTNICZA
WYDZIAŁ INŻYNIERII MECHANICZNEJ I ROBOTYKI**

TEMATYKA PRACY DYPLOMOWEJ

Grzegorz Tworek

.....
imię i nazwisko studenta

Tytuł pracy dyplomowej:

Analiza przydatności sztucznej sieci neuronowej w ocenie pracy serca

Promotor pracy: *dr hab. inż. Wiesław Wszolek*

Recenzent pracy: *dr hab. inż. Maciej Kłaczyński*

.....
Podpis dziekana

PLAN PRACY DYPLOMOWEJ

1. Omówienie tematu pracy i sposobu realizacji z promotorem.
2. Zebranie i opracowanie literatury dotyczącej tematu pracy.
3. Pozyskanie i opracowanie danych.
4. Przeprowadzenie badań.
5. Opracowanie wyników badań.
6. Analiza wyników badań, ich omówienie i zatwierdzenie przez promotora.
7. Opracowanie redakcyjne.

Praktyka (dyplomowa):

Akademia Górniczo-Hutnicza, Wydział Inżynierii Mechanicznej i Robotyki, Katedra Systemów Energetycznych i Urządzeń Ochrony Środowiska

Kraków,
data podpis dyplomanta

.....
podpis promotora

Termin oddania do dziekanatu: 20..... r.

Spis treści

1. Wstęp	8
1.1 Cel pracy	8
1.2 Zakres pracy	8
2. Uczenie maszynowe, a sztuczna inteligencja	9
2.1 Opis zagadnienia	9
2.2 Wyzwania stojące przed uczniem maszynowym.....	10
3. Sztuczne sieci neuronowe	10
3.1 Neurony w sztucznych sieciach neuronowych.....	11
3.2 Warstwy sztucznej sieci neuronowej.....	12
3.3 Proces uczenia	13
3.3.1 Uczenie z nauczycielem	13
3.3.1.1 Reguła najmniejszego spadku w uczeniu z nauczycielem	13
3.3.2 Uczenie bez nauczyciela.....	14
3.3.2.1 Reguła Hebba w samouczeniu sieci.....	14
3.4 Epoki	15
3.5 Sieci nieliniowe a liniowe	16
3.6 Perceptron	16
3.5 Adaline i madeline	17
3.5.1 Adeline	17
3.5.2 Madeline	18
3.6 Algorytm wstecznej propagacji błęd.....	18
3.7 Przeuczenie sieci.....	18
3.5 Rodzaje sieci neuronowych	19
3.5.1 Genetyczna sieć neuronowa	19
3.5.2 Sieć konkurencyjne (Kohonena).....	20
3.5.3 Sieci rekurencyjne.....	21
4. Elektroardiografia	22
4.1 Fizjologia układu serca.....	22
4.2 Badanie EKG.....	24
4.3 Zespół QRS.....	26
4.4 Dyskretyzacja sygnału EKG	27
4.5 Zakłócenia.....	28
4.6 Metody redukcji zakłóceń	29

4.6.1 Uśrednianie sygnału.....	29
4.6.2 Filtracja.....	29
4.7 Rejestracja sygnału elektrokardiograficznego metodą Holtera.....	30
5. Detekcja podstawowych zjawisk na podstawie zapisu Holtera	32
5.1 Detekcja zespołu QRS	32
5.1.1 Algorytmy identyfikacyjne stosowane w sztucznych sieciach neuronowych	33
5.2 Detekcja arytmii.....	33
5.3. Analiza pracy kardiostymulatora.....	35
5.4. Sieci falkowo-neuronowe.....	36
6. Zastosowanie sztucznej sieci neuronowej do rozpoznawania sygnałów elektrokardiograficznych	37
6.1 Konwersja sygnałów do obrazów	38
6.1.1 Parametry ciągłej transformaty falkowej.....	39
6.2 Implementacja sztucznej sieci neuronowej	40
6.2.1 Sieć konwolucyjna.....	40
6.2.2 Struktura sieci konwolucyjnej	40
6.2.3 Składnia warstw w zaimplementowanej sztucznej sieci neuronowej	41
6.2.4 Parametry uczenia sztucznej sieci neuronowej	43
6.3 Zebranie wyników sieci	44
7.Wnioski	47
8. Bibliografia	48
9. Załączniki	51

1. Wstęp

Spotykane są różne rodzaje problemów i zagadnień, których nie można sformułować w postaci prostego algorytmu. Zagadnienia te zależą od pewnych ściśle określonych czynników. Kwestie takie jak rozpoznawanie twarzy, oszacowanie cen produktów czy kojarzenie zdarzeń są łatwe do wykonania przez człowieka, ale trudne do przedstawienia w postaci algorytmu zaprogramowanego w komputerze. Człowiek do myślenia i podejmowania decyzji wykorzystuje mózg, który składa się z 10^{11} neuronów i 10^{15} połączeń, które razem tworzą sieć neuronową. Neurony przetwarzają sygnał w sposób nieliniowy łącząc się z innymi odpowiadającymi neuronami. Wiedza ta przyczyniła się do powstania sztucznych sieci neuronowych gdzie do przetworzenia informacji wykorzystuje się algorytmy, których działanie opiera się na właściwościach neuronów biologicznych.

Jedną z najbardziej powszechnych metod diagnostyki kardiologicznej jest wystawienie diagnozy stanu zdrowia pacjenta na podstawie sygnałów elektrokardiograficznych (EKG). Proces ten nie został jeszcze w pełni zautomatyzowany, co sprawia, że jest atrakcyjną dziedziną zastosowań dla sztucznych sieci neuronowych.

1.1 Cel pracy

Celem pracy było zaimplementowanie w środowisku Matlab systemu do analizy zapisów (rejestracji) EKG z wykorzystaniem sztucznych sieci neuronowych. Zaprogramowany system będzie służył do analizy i rozpoznawania trzech rodzajów sygnałów EKG pobranych metodą Holtera.

1.2 Zakres pracy

W części teoretycznej pracy przedstawiono pojęcie sztucznej inteligencji, omówiono sztuczne sieci neuronowych i ich rodzaje. Następnie opisano zagadnienie elektrokardiografii, przedstawiono metody badań i pozyskiwania sygnałów elektrokardiograficznych.


W części projektowej przy użyciu sztucznych sieci neuronowych, zaimplementowano sztuczną sieć neuronową przy użyciu danych pochodzących z Physionetu z ogólnodostępnej bazy MIT-BIH. Zastosowane sygnały są przyporządkowane do trzech grup: arytmii, zastoinowej niewydolności serca i normalnego rytmu zatokowego.

2. Uczenie maszynowe, a sztuczna inteligencja

Sztuczna inteligencja AI (ang. Artificial Intelligence) to bardzo ogólne pojęcie, które może oznaczać kilka różnych form technologii. Natomiast uczenie maszynowe (ang. Machine Learning) odnosi się do konkretnego rodzaju technologii. Innymi słowy używamy terminu uczenia maszynowego do wskazania konkretnej grupy technologicznej sztucznej inteligencji. Samo uczenie maszynowe obejmuje kilka innych dziedzin, jedną z nich jest na przykład głębokie uczenie (ang. Deep Learning).

2.1 Opis zagadnienia

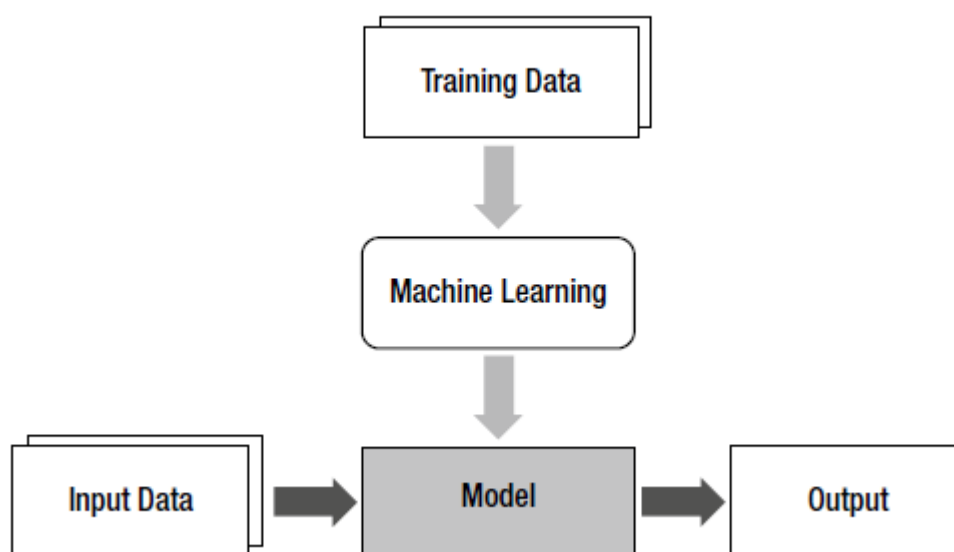
Uczenie maszynowe jest techniką modelowania, która opiera się na wykorzystywaniu danych. Oznacza, to że uczenie maszynowe analizuje dane i tworzy na podstawie nich model. Proces ten nazywamy uczeniem ponieważ przypomina bycie szkolonym z danymi do rozwiązywania jakiegoś problemu. W związku z tym dane, które są wykorzystywane w procesie modelowania nazywamy danymi „szkoleniowymi”. Uproszczony schemat procesu uczenia maszynowego pokazano na rys. 2.1



Rys. 2.1 Proces uczenia maszynowego [5]

2.2 Wyzwania stojące przed uczniem maszynowym

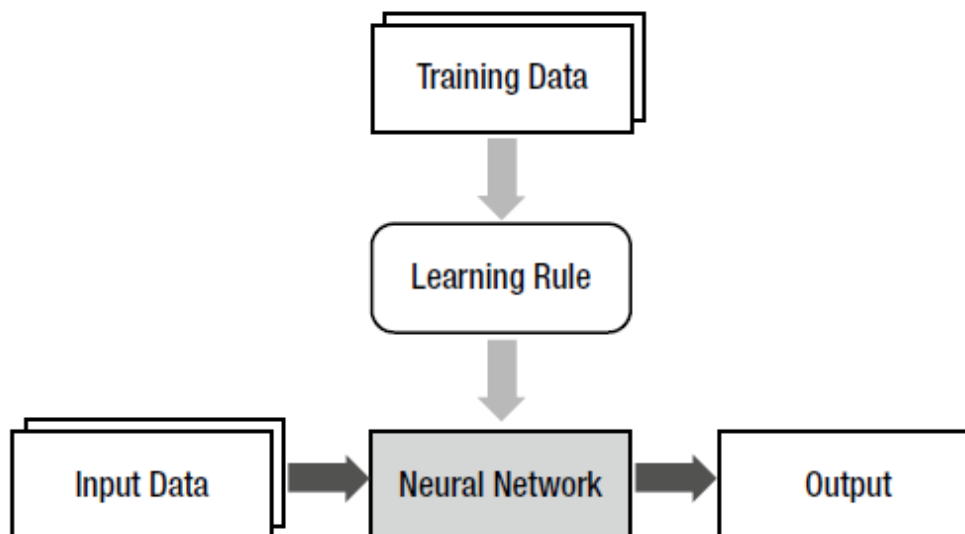
Podsumowując uczenie maszynowe wykorzystujemy do zagadnień, które wymagają inteligencji takich jak rozpoznawanie obrazów i dźwięków, gdzie podstawowe prawa fizyki bądź równania matematyczne są trudne (albo wręcz niemożliwe) do zrealizowania. Kiedy uda się stworzyć model neuronowy z danych szkoleniowych można go wykorzystać do rozpoznania danych wejściowych co zostało przedstawione na rys. 2.2.



Rys. 2.2 Wykorzystanie modelu do rozpoznania danych wejściowych [5]

3. Sztuczne sieci neuronowe

W tym rozdziale zostaną przedstawione sztuczne sieci neuronowe, które są szeroko stosowane jako modele w uczeniu maszynowym. Sztuczne sieci neuronowe mają długą historię rozwoju i są często opisywane w książkach związanych z tematyką sztucznej inteligencji. Modele w uczeniu maszynowym mogą być przedstawione w różnych formach jedną z nich są właśnie sztuczne sieci neuronowe co przedstawiono na rys.3.1. W porównaniu do rys. 2.2 uczenie maszynowe zastąpiono procesem uczenia, a model siecią neuronową. Sieć neuronową możemy rozumieć jako „pewną architekturę systemu komputerowego, która odpowiada za przetworzenie danych przez modele neuronów ustawionych w warstwy. Wymagane rezultaty otrzymuje się poprzez proces uczenia, który odnosi się do modyfikacji wag tych neuronów, które odpowiadają za błędy”.




Rys. 3 Sztuczne sieci neuronowe w uczeniu maszynowym [5]

3.1 Neurony w sztucznych sieciach neuronowych

Za każdym razem, gdy człowiek się czegoś nauczy, przechowuje tę wiedzę w mózgu. Komputery używają pamięci do przechowywania informacji. Pomimo tego, że komputer i człowiek magazynują dane to mechanizm działania jest inny. Komputer przechowuje informacje w określonych miejscach pamięci, podczas gdy mózg modyfikuje połączenia między neuronami. Sam neuron nie ma zdolności magazynowania tylko wysyła sygnały z jednego neuronu do drugiego. Mózg to właśnie gigantyczna sieć tych neuronów, a odpowiednie połączenia neuronów tworzą konkretne informacje.

Sieć neuronowa imituje działanie mózgu, składa się ze sztucznych neuronów, które opowiadają neuronom biologicznym. Sztuczna sieć neuronowa odwzorowuje połączenia neuronów poprzez wykorzystanie wartości wag rys. 3.2.




Rys. 3.1 Uproszczony model sztucznego neuronu [6]

Do wejść doprowadzane są sygnały lub wartości na przykład z poprzedniej warstwy neuronów. Wartości są wprowadzane do neuronu poprzez połączenia. Na każdym połączeniu znajduje się waga przez którą musi zostać pomnożony wprowadzany sygnał. W neuronie ważone wejścia są sumowane, a następnie od uzyskanego wyniku odejmowana jest wartość progowa. Łączny sygnał przechodzi w stan pobudzenia tylko wtedy, gdy przekroczy poziom progowy. Następnie w bloku aktywacji sygnał jest przekształcony przez funkcje aktywacji gdzie obliczona zostaje wartość wyjściowa neuronu

3.2 Warstwy sztucznej sieci neuronowej

Sieci neuronowe wraz z rozwojem technologii rozwinęły się od prostej architektury do złożonych struktur. Początkowo sieci neuronowe miały prostą budowę z wejściami i wyjściami, sieci takie nazywano jednowarstwowymi. Później do sieci jednowarstwowch zaczęto dodawać warstwy ukryte co doprowadziło do powstania sieci wielowarstwowch. W wielowarstwowej sieci neuronowej sygnał wchodzi warstwy wejściowej, przechodzi przez warstwy ukryte, a wychodzi przez warstwę wyjściową. Podczas tego procesu sygnał rozwija się warstwa po warstwie innymi słowy neurony w warstwie odbierają sygnał jednocześnie i wysyłają przetworzony sygnał do następnej warstwy w tym samym czasie. Prosty przykład przetwarzanie danych wejściowych z jedną warstwą ukrytą został przedstawiony na rys. 3.3



Rys 3.2. Sieć neuronowa z jedną warstwą ukrytą [5]

3.3 Proces uczenia

Sieci neuronowe działają inaczej niż klasyczne programy komputerowe nawet, gdy nie jest znany algorytm można rozwiązać dane zagadnienie. Sieć można uczyć na dwa sposoby: uczenie z nauczycielem – nadzorowane (supervised learning) i uczenie bez nauczyciela – nienadzorowane (unsupervised learning).

3.3.1 Uczenie z nauczycielem

Uczenie z nauczycielem polega na tym, że sieci podaje się odpowiednie sygnały wejściowe i wyjściowe, prezentując jednocześnie jaka powinna być odpowiedź przy danej konfiguracji danych wejściowych. Sieć sprawdza jakie są związki między danymi wejściowymi, a wymaganymi rezultatami (wynikiem na wyjściu) dzięki czemu uczy się odpowiedniego schematu prowadzącego do prawidłowego wyniku.

Należy zwrócić uwagę, że przy uczeniu z nauczycielem zawsze występuje para wartości to znaczy przykładowy sygnał wejściowy i pożądane wyjście czy też wymagana odpowiedź sieci. Sieć może mieć oczywiście składać się z dużej ilości wejść i wyjść wtedy wspomniana para oznacza dwa zbiory wartości. Zbiór danych wejściowych oraz zbiór danych na wyjściu, które powinny stanowić rozwiązanie zadania.

Nauczycielem w powyższej metodzie uczenia można traktować program komputerowy wyposażony w odpowiedni zbiór uczący. Zbiorem uczącym jest zbiór danych który musi zostać odpowiednio skonfigurowany. Oznacza to, że należy wyraźnie wskazać, które dane zostaną użyte jako dane wejściowe, a które jako wyjściowe. Nie należy też umieszczać w sieci danych, które będą nie są użyteczne do znalezienia rozwiązania dla danego zagadnienia.

3.3.1.1 Reguła najmniejszego spadku w uczeniu z nauczycielem

Neuron po otrzymaniu informacji od danych wejściowych, albo od innych neuronów wytwarza sygnał wyjściowy na podstawie wiedzy o ustalonych wcześniej współczynnikach wag. Wartość sygnału wychodzącego z neuronu jest określana poprzez porównanie z odpowiedzią wzorcową w ciągu uczącym. W przypadku wystąpienia rozbieżności między sygnałem wyjściowym z neuronu, a wartością prawidłową neuron wyznacza poszukiwaną różnicę i przy pomocy reguły najmniejszego spadku zmienia wartości wag, aby zminimalizować błąd. Do prawidłowego ocenienia współczynników wagowych wykorzystuje się wzór na sumę kwadratów, aby zminimalizować

występowanie błędów dodatnich i ujemnych. Z otrzymanych wyników tworzy się powierzchnie błędów nazwaną też funkcją błędów. Składa się z pagórków i dolin. Pagórki symbolizują miejsca z największą ilością błędów, a doliny miejsca z małą ilością błędów. Proces uczenia metodą najmniejszego spadku polega na takim doborze wag, aby uzyskać najbardziej optymalną drogę zmniejszania się błędów z pagórków do dolin.

3.3.2 Uczenie bez nauczyciela

Uczenie bez nauczyciela, albo sieć samoucząca się polega na podawaniu do sieci tylko danych wejściowych bez żadnych informacji o pożądanym lub oczekiwanym sygnale wyjściowym. Odpowiednio skonstruowana sieć neuronowa potrafi na podstawie samych danych wejściowych zbudować sprawny algorytm swojego działania. Taki algorytm zazwyczaj polega na automatycznym wykrywaniu powtarzających się klas danych wejściowych dzięki czemu sieć uczy się identyfikować odpowiednie wzorce sygnałów.

W sieciach nienadzorowanych również niezbędny jest zbiór uczący z tym, że w tym zbiorze występują same dane wejściowe. Brak danych wejściowych oznacza, że metoda uczenia bez nauczyciela jest stosowana kiedy nie wiadomo jakiego rezultatu należy się spodziewać po sieci analizującej dane.

Samouczenie sieci odpowiada też pewnym cechom ludzkiego umysłu. Człowiek również posiada zdolność do klasyfikowania zjawisk i obiektów. Po dokonanej klasyfikacji sam przyporządkowuje kolejne napotkane obiekty do wcześniej ustalonych klas. Sieci nienadzorowane są też atrakcyjne pod względem zastosowań ze względu na to że nie wymagają żadnej zewnętrznej wiedzy, której zdobycie może być bardzo trudne albo nawet niemożliwe.

3.3.2.1 Reguła Hebb'a w samouczeniu sieci

Jedną z podstawowych koncepcji samouczenia sieci neuronowej jest metoda amerykańskiego fizjologa Donalda Hebb'a. Metoda opiera się na obserwacji połączeń neuronowych w mózgach zwierząt. Według Hebb'a połączenia między neuronami zostają wzmacniane jeśli zostaną pobudzone jednocześnie. W ten sposób kształtują się skojarzenia i podstawowe zdolności percepcyjne i ruchowe.

W oparciu o teorie Hebb'a stworzono regułę samouczenia sieci, która polega na tym, że sieci dostarczane są sygnały bez żadnych informacji co należy z nimi zrobić w ten sposób sieć sama rozpoznaje znaczenie obiektów i tworzy zależności pomiędzy sygnałami. Proces uczenia w tej metodzie opiera się na tym, że wraz z zwiększającą się ilością danych w sieci tworzy się rozkład danych wejściowych oznacza, to że niektóre neurony są pobudzane silniej a niektóre słabiej. Dzięki czemu niektóre neurony rozpoznają wprowadzane sygnały za pozytywne, obojętne lub negatywne. Po wprowadzeniu wszystkich sygnałów wejściowych wagi neuronów w sieci są zmieniane. Zmiana wagi zależy od iloczynu sygnałów wejściowych do neuronu i sygnału wyjściowego wychodzącego przez dany neuron. Powyższy mechanizm działania sieci opiera się właśnie na regule Hebb'a o reagowaniu na niektóre bodźce silniej, a na inne słabiej.

3.4 Epoki

Proces uczenia sieci neuronowej wymaga bardzo wiele iteracji algorytmu uczącego zanim zostanie uzyskany akceptowalny błąd. Zazwyczaj ilość danych w zbiorze uczącym jest dużo za mała w porównaniu do wymaganej liczby iteracji algorytmu uczącego. Wynika z tego, że do uzyskania zadawalających rezultatów zbiór uczący musi zostać wykorzystany wielokrotnie. Wiąże się to z pojęciem epoki, które można rozumieć jako pojedyncze wykorzystanie elementów w zbiorze uczącym w procesie uczenia sieci. Po przeprowadzeniu wszystkich kroków w jednej epoce algorytm sprawdza sieć pod kątem generalizacji wyników z wykorzystaniem zbioru walidacyjnego. Jeżeli błąd dla zbioru uczącego jak i błąd dla zbioru walidacyjnego mają tendencje malejącą algorytm przeprowadza kolejną epokę. Jeżeli błędy nie maleją to uczenie sieci zostaje zatrzymane.

Gdyby dane uczące dostarczać do sieci w tej samej kolejności to proces zmian wag w sieci może ulec zapętleniu i wagi mogłyby cały czas powracać do tych samych wartości. Aby temu zapobiec stosuje się randomizację danych uczących w postępujących po sobie epokach, czyli kolejność pojawiania się danych uczących w każdej epoce jest inna. Wagi zostają wtedy dopasowywane w sposób uporządkowany zmierzając do najbardziej optymalnego rozwiązania i minimalizacji błędu.

3.5 Sieci nieliniowe a liniowe

Przewagą sieci nieliniowe nad liniowymi jest, że mogą rozwiązywać szerszą gamę zagadnień od sieci liniowych. Porównanie obu sieci opiera się na ich podstawowych właściwościach jednorodności i addytywności.

Odwzorowanie uważamy za jednorodne jeśli skutek jest powiązany z przyczyną. Oznacza, to że skutek zmienia się proporcjonalnie do przyczyny wtedy takie odwzorowanie nazywamy jednorodnym. W przypadku, gdy zachodzi nieproporcjonalna zmiana skutku do przyczyny wtedy mówimy o odwzorowaniu nieliniowym.

Addytywność opisuje zależność pomiędzy dwoma badaniami z różnymi przyczynami i skutkami. Jeżeli badanie zostanie wykonane dla sumarycznie połączonych ze sobą przyczyn i skutek dla takiego badania będzie dokładną sumą skutków dla dwóch badań wykonanych oddzielnie dla tych przyczyn. To takie zjawisko nazywamy addytywnością.

3.6 Perceptron

Zwykły perceptron jest przypisywany do określenia jednokierunkowych sieci neuronowych z nadzorowaną metodą uczenia. Sieci te służą zazwyczaj do klasyfikacji i rozpoznawania obrazów. Pierwszy raz nawa perceptron została użyta do określenia sieci neuronowej zbudowanej przez Franka Rosenblatta w 1960 roku.

Perceptronem wielowarstwowym (Multilayer Perceptron MLP) nazwano sieć jednokierunkową składającą się z warstwy wejściowej, kilku warstw ukrytych oraz warstwy wyjściowej. MLP jest najpowszechniej stosowaną siecią nieliniową. Neurony w warstwach mają jeden kierunek przepływu, a połączenia znajdują się tylko między sąsiednimi warstwami. W perceptronie wielowarstwowym funkcja agregująca jest liniowa, a z kolei funkcja aktywacji nieliniowa. Uczenia odbywa się metodą wstecznej propagacji błędów, a warstwy ukryte i warstwa wyjściowa są zbudowane z neuronów sigmoidalnych.

3.5 Adaline i madeline

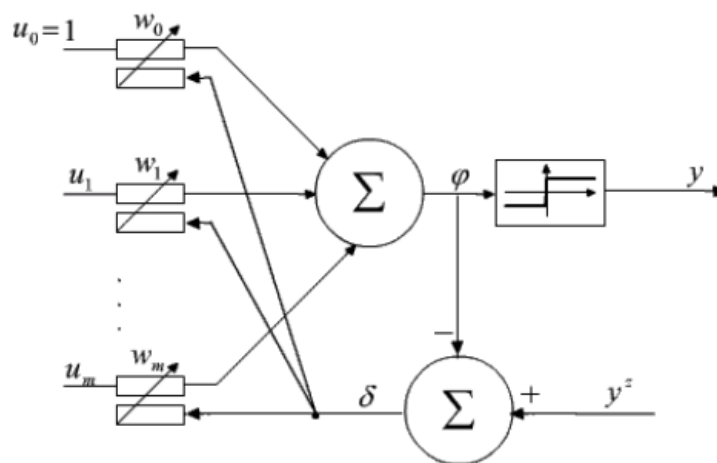
3.5.1 Adaline

Strukturę Adaline można definiować na dwa sposoby. Pierwszy określa ją jako liniowy element przetwarzający gdzie sygnał wyjściowy został opisany w następujący sposób:

$$y = \varphi = \sum_{i=0}^m w_i u_i \quad (3.6)$$

indeks $i=0$ oznacza element progowy z doprowadzonym sygnałem u_i równym. Element Adaline nie posiada współczynnika liniowego, rolę tego współczynnika pełnią wagi połączeń między warstwami sieci.

Druga definicja elementu Adaline jest bardzo podobna do neuronu perceptronowego. Obok sumatora zwanego ALC (ang. Adaptive Linear Combiner) stosowany jest blok aktywacji wykorzystujący bipolarną funkcję signum. Element Adaline różni się także metodą uczenia, gdyż stosuje się w nim minimalizację błędu średniokwadratowego (ang. Least mean square LMS). Dla perceptronu zmiana wag opiera się na wartości wyjściowej z bloku aktywacji w przypadku elementu Adaline uwzględnia się wynik na sumatorze ALC. Algorytm uczenia dla elementu Adaline można opisać w następujący sposób. Najpierw wprowadzony zostaje wektor wejściowy u potem wyznacza się błąd pomiędzy oczekiwaną a otrzymanym sygnałem wyjściowym, następnie określa się wektor wag. Algorytm się powtarza dopóki suma kwadratów błędów będzie wystarczająco mała.



Rys 3.5. Schemat uczenia Adaline [28]

3.5.2 Madeline

Neuron Adaline i neuron perceptronowy poza podobną budowę mają też podobne ograniczenia m. in. element Adaline nie jest w stanie poradzić sobie z problemem XOR. Tak jak w perceptronów można utworzyć perceptron wielowarstwowy MLP tak z elementów Adaline można stworzyć sieć typu Madeline.

Struktura sieci Madeline jest na tyle złożona, że algorytm minimalizacji błędu średniokwadratowego będzie nieskuteczny do uczenia całej sieci. Metoda LMS wymaga znajomości wejść i wyjść w każdej warstwie, a takich informacji trudno uzyskać. Algorytm sprawdza się w przypadku wyjść dla sumatora ALC. W sieci Madeline sygnały wyjściowe przyjmują wartości bipolarne, z którymi algorytm LMS sobie nie radzi. Stosuje się w takim przypadku metodę bazującą na algorytmie LMS. Metodą to jest metoda wstecznej propagacji błędu.

3.6 Algorytm wstecznej propagacji błędu

Algorytm wstecznej propagacji błędu (ang. Backpropagation) jest jednym z podstawowych algorytmów stosowanych do nadzorowanego uczenia jednokierunkowych wielowarstwowych sieci. Algorytm polega na zmianie wag między dowolnymi połączeniami neuronów znajdujących się w sąsiednich warstwach sieci. Wsteczna propagacja błędu opiera się na metodzie minimalizacji błędu średniokwadratowego z uwzględnieniem zoptymalizowanej metody największego spadku. Metoda wstecznej propagacji dzięki swojemu specyficznemu podejściu jest jednym z bardzo skutecznych metod uczenia sieci.

3.7 Przeuczenie sieci

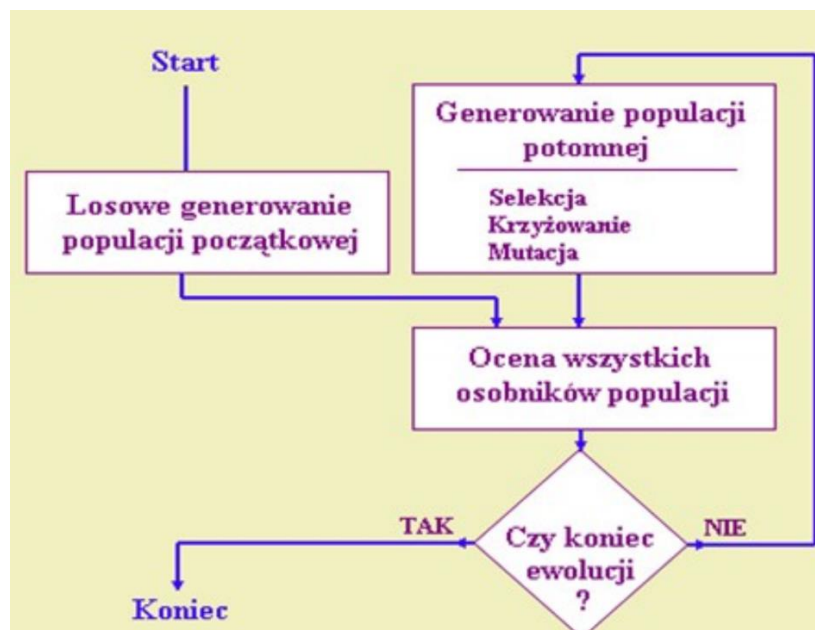
Niekiedy zbyt długie uczenie może doprowadzić do negatywnego zjawiska określanego jako przeuczenie sieci. Przeuczenie powoduje, że sieć nadmiernie uzależnia swoje wyniki od drugorzędnych cech przypadków uczących. Istotę tego zagadnienia można porównać do dopasowania modelu za pomocą wielomianów. Istotne jest, to aby model został dopasowany do kształtu aproksymowanej zależności, a nie do szczegółów otrzymywanych z pojedynczych danych.

3.5 Rodzaje sieci neuronowych

3.5.1 Genetyczna sieć neuronowa

Genetyczne sieci neuronowe są wynikiem połączenia sztucznych sieci neuronowych z algorytmami genetycznymi. Algorytmy genetyczne są metodą optymalizacji struktury sieci neuronowej. Schemat działania sieci genetycznej polega na wyborze pewnych początkowych struktur sieci, które są określane mianem populacji, następnie przeprowadzane jest selekcja na podstawie wyników uczenia. Struktury, które osiągnęły najlepsze rezultaty poddawane są krzyżowaniu. Krzyżowanie polega na wymianie losowych parametrów dla pary rozwiązań. Na otrzymane rozwiązania są przeprowadzane losowe zmiany nazywane mutacjami. Tak przygotowane wyniki nazywamy potomnymi. Rozwiązania potomne przyjmują wtedy rolę rozwiązań potomnych w populacji dzięki czemu cykl się zapętla.

Sieci genetyczne wyróżniają się tym, że podczas optymalizacji nie tylko jest przeprowadzany proces uczenia, ale także wybór odpowiedniej struktury sieci. Dodatkowo genetyczne sieci neuronowe są oceniane pod względem nieliniowych połączeń neuronowych oraz prezentują różne sprawne sposoby rozwiązań danego zagadnienia. Wadą sieci genetycznych jest długi czas obliczeń ze względu na trening wszystkich sieci w populacji i następujących epokach.




Rys 3.5.1. Schemat algorytmu genetycznego [24]

3.5.2 Sieć konkurencyjne (Kohonena)

Niektóre sieci w warstwie wyjściowej lub w mapach topologicznych posiadają mechanizm konkurencji, charakteryzujący się porównywaniem wartości wyjściowych sieci. Spośród sygnałów wyjściowych z sieci lub mapy topologicznej wybiera się tego o największej wartości i nadaje mu miano zwycięskiego. Zmiany wag dotyczą zwycięskiego neuronu lub niektórych przypadkach również jego sąsiedztwa.

Siecią konkurencyjną, która opiera się na zasadzie sąsiedztwa zwycięskiego neuronu jest sieć Kohonena. Proces uczenia tej sieci wiąże się z powstaniem mapy topologicznej. Mapy nie da się jednoznacznie zinterpretować, ale można określić znaczenie niektórych z jej rejonów opierając się na danych wejściowych. Struktura sieci Kohonena na rys 3.5.2 ma jedynie charakter poglądowy. Prawdziwe sieci składają się z wielu sygnałów wejściowych działających na dużej ilości wielowymiarowych przestrzeni.

Neurony w warstwie topologicznej odpowiadają za identyfikację obiektów, które zostały wprowadzone do sieci jako dane wejściowe. Jeśli obiekt wprowadzony do sieci zostanie rozpoznany to przyporządkowany do tego obiektu neuron zostaje zwycięzcą




Rys 3.5.2. Struktura sieci Kohonena [25]

3.5.3 Sieci rekurencyjne

Sieci rekurencyjne wyróżniają się posiadaniem w swojej strukturze sprzężeń zwrotnych. Dzięki sprzężeniom zwrotnym sygnały z warstw odległych od warstwy wejściowej trafiają ponownie na wcześniejsze warstwy lub na wejście sieci.

W sieciach rekurencyjnych występują zjawiska zupełnie niespotykane w innych sieciach. Raz pobudzona sieć ze sprzężeniem zwrotnym będzie generować całe kombinacje sygnałów. Sygnały z wyjścia trafiając z powrotem na wejście sieci po n-tej iteracji, generują powstanie zupełnie nowych sygnałów wejściowych. Tego typu zapętłone cykle sygnałów powodują powstanie w sieci zjawisk takich jak oscylacje, dławienie sygnałów czy też występowanie przebiegów nie zdeterminowanych.

Sieci rekurencyjnych nie stosuje się często ze względu na swoje duże złożoności w obiegach sygnałów. Każdy wprowadzony sygnał musi przejść długą drogę przez stany pośrednie zanim sieć się ustabilizuje. W rezultacie sieci zapętłone są bardzo trudne do analizy i tym samym kosztowne czasowo.



Rys 3.5.2. Struktura sieci rekurencyjnej [26]

4. Elektrokardiografia

Elektrokardiografia ma za zadanie ocenę pracy serca na podstawie zjawisk elektrycznych. Włókna w mięśniu sercowym mają zdolność do samoistnego przekazu pobudzeń co prowadzi do aktywacji wszystkich zdolnych do pracy komórek serca. Dzięki takiej skoordynowanej pracy komórek możliwe jest wyróżnienie poszczególnych faz skurczu z użyciem sygnałów elektrodiagnostycznych. Przebieg elektrokardiograficzny pozwala zidentyfikować postępujące po sobie etapy pracy serca. Najbardziej przydatne są parametry czasowe i morfologiczne. Parametry czasowe pozwalają określić zjawiska związane ze skurczem i rozkurczem serca, z kolei parametry morfologiczne pozwalają określić początek i przebieg impulsu elektrycznego.


4.1 Fizjologia układu serca

Pobudzenie do pracy jednej z komórek w mięśniu sercowym może wiązać się z rozprzestrzenianiem fali depolaryzacji, która przeniesie się na kolejne włókna mięśniowe, a z nich na następne. Szybkość z jaką jest przewodzony bodziec zależy od kierunku ustawienia włókien i waha się od 400mm/s do 200mm/s. Za taki przebieg impulsów odpowiedzialny jest układ bodźcotwórczo-bodźcoprzewodzący składający się z włókien kurczliwych. Włókna te posiadają zdolność do samoistnego wytwarzania bodźców czyli depolaryzacji.

Wspomniany układ bodźcowy składa się z:

- Węzła zatokowo-przedsionkowego, znajdującego się przy ujściu głównej żyły od prawego przedsionka. Węzeł odpowiada za generowanie rytmu kierowanego przez współczulny i przywspółczulny układ nerwowy. U człowieka sterowanie układem poprzez przeciwstawne działanie układu współczulnego i przywspółczulnego, a więc poprzez antagonistyczne pobudzanie i hamowanie.
- Szlaku międzyprzedsionkowego dostarczającego impuls do lewego przedsionka
- Szlaków międzywęzłowych: przedni, środkowy i tylni.
- Węzła przedsionkowo-komorowego, znajdującego się pod prawym przedsionkiem zdolnego do wytwarzania bodźców o częstotliwości od 45 do 60 1/min. Węzeł odpowiada za przekazania bodźca od przedniego szlaku międzywęzłowego do pęczka Hisa. Bodziec dochodzący do pęczka jest opóźniony o 120ms przez co skurcze przedsionków są szybsze od skurczy komór.

- Pęczek Hisa, dzieli się na prawą i lewą odnogę. Odnogi przekazują bodziec z prędkością 2000mm/s. Lewą odnogę można podzielić na wiązki: przednią, tylną i przegrodową.
- Włókien Purkiniego, to zakończenia wiązek w pęczku Hisa. Są ostatnimi elementami w układzie przekazującym bodźce. Potem pobudzenia trafiają do mięśni komór.



Rys 4.1. Układ przewodzący serca [29]

Przy prawidłowej pracy serca za pobudzenie odpowiada węzeł zatokowo-przedsionkowy. Z węzła impuls przechodzi do prawego przedsionka, a przez szlak międzyprzedsionkowy do lewego przedsionka. Taki przebieg pobudzenia jest związany z kierunkiem pola elektrycznego, najpierw w prawo, potem w dół i na końcu w lewo, aż pole elektryczne ulegnie wygaszeniu. Wiąże się to z sytuacją gdy wszystkie komórki przy przedsionkach są pobudzone, ale z powodu przedłużonej refrakcji komórki nie są w stanie przyjąć pobudzenia. Dochodzi wtedy do depolaryzacji przedsionków, a wypadkowy wektor pola elektrycznego zapętla się w przestrzeni. Zarejestrowana zmiana napięcia jest widoczna na elektrokardiogramie jako załamek P.

Impuls z węzła zatokowo-przedsionkowego przesyłany jest też do węzła przedsionkowo-komorowego, gdzie przechodzi przez ośrodek, w którym prędkość przewodzenia gwałtownie maleje. Przez ok. 120ms na elektrokardiogramie nie są widoczne żadne zjawiska. Moment ten nazywany jest linią izoelektryczną, która stanowi punkt odniesienia do interpretacji sygnału elektrokardiograficznego.


Gdy impuls przejdzie przez pęczek Hisa dochodzi do depolaryzacji w przegrodzie międzykomorowej. Impuls pobudzający ulega przyśpieszeniu i wektor pola elektrycznego zmienia swój kierunek z prawa do dołu. Później pobudzenie krąży już w komórkach mięśniowych. W prawej komorze gdzie ściany zewnętrzne są bardzo cienkie i bardzo szybko następuje stan nasycenia.

Masa mięśniowa lewej komory jest 10 razy większa od prawej w związku z tym impuls rozchodzi się dużo wolniej. Wektor pola jest w kierunku lewym, a długość wektora jest zależna od wygasania pobudzenia. Przy stanie nasycenia wektor pola elektrycznego zapętla się drugi raz przy dużo większej amplitudzie. Skurcz komór jest zarejestrowany przez elektrody jako wahanie napięcia i nosi miano zespołu QRS.

Komórki, w których zaszła depolaryzacja ulegają też repolaryzacji, czyli powrocie do spoczynkowej różnicy potencjałów. Repolaryzacja komórek mięśniowych w przedsionkach zachodzi jednocześnie ze skurczem komór, dlatego nie można zarejestrować żadnych zmian związanych z tym zjawiskiem. Repolaryzacje w komorach można za to bardzo dobrze zaobserwować. Początki repolaryzacji tworzą się w warstwach zewnętrznych mięśnia sercowego i stopniowo zmierzają do warstw wewnętrznych. W związku z tym, że kierunek i biegunowość repolaryzacji są przeciwne do depolaryzacji można zaobserwować synchroniczną zmianę pola elektrycznego. Wektor pola zapętla się wtedy trzeci raz, a na elektrokardiogramie jest zarejestrowane wychylenie nazywane załamkiem T.

4.2 Badanie EKG

W medycynie EKG należy do nieinwazyjnych metod badań. Podczas badania na ciele pacjenta umieszcza się elektrody w odpowiednich punktach ciała, pomiarowi podlega różnica potencjałów w czasie pomiędzy odpowiednimi elektrodami. Pierwszy elektrokardiogram został opublikowany w 1887 r. przez A. D. Wallera przy użyciu elektrometru kapilarnego później w 1902 r. W. Einthoven opublikował pierwszy elektrokardiogram na galwanometrze strunowym. Przez ponad sto lat rozwoju przetwarzania sygnałów i technologii wyodrębniono kilka sposobów pozyskiwania sygnału elektrokardiograficznego. Stosowane metody to np.: standardowe badanie EKG z dwunastoma odprowadzeniami, pomiar EKG metodą Holtera z 24 godzin pomiar EKG w teście wysiłkowym.



Rys 4.2. Ustawienie elektrod w 12-odprowadzeniowym badaniu EKG [30]

Ustawienie elektrod dwubiegunowych kończynowych oraz jednobiegunowych kończynowych rys. 4.2. prowadzi do nagromadzenia się nadmiaru informacji podczas badania. Dlatego kardiolodzy zwykle rejestrują sygnał z dwóch odprowadzeń, a pozostałe rekonstruują matematycznie opierając się na prawach Kirchhoffa. W przypadku


odprowdzeń przedsercowych taka praktyka jest niemożliwa. Mimo iż elektrody są blisko siebie to dostarczają dużo niezależnych informacji.

Przetwarzanie otrzymanych sygnałów jest analogiczne dla wszystkich kanałów główne znaczenie ma tu umiejscowienie elektrody. Ustawienie elektrod wykorzystuje się głównie do znalezienia osi elektrycznej co wiąże się ze znalezieniem położenia serca w ciele badanego. Ponieważ sygnały przedstawiają zwykle ten sam przypadek elektrofizjologiczny (ale z różnej perspektywy) duże znaczenie ma tu wybór wszystkich czy tylko poszczególnych z odebranych sygnałów. Jest to często stosowana praktyka na przykład do oceny rytmu i morfologii serca, czy też określeniu długości załamków. Niekiedy mogą się zdarzyć przypadki, że położenie elektrody znajdzie się w tym samym miejscu, w którym dochodzi do zmienności zjawisk elektrofizjologicznych. Załamki odbierane z takiego odprowadzenia mogą być wtedy niewidoczne, w takim przypadku do identyfikacji zjawiska wykorzystuje się informacje z pozostałych elektrod.

Badanie elektrokardiograficzne ma za zadanie przekazać informacje o pracy serca pacjenta, a także wykryć potencjalne choroby układu krążenia. Diagnozowanie stanu zdrowia pacjenta polega obserwacji wychyleń w sygnale EKG. Wychylenia nazwano literami P,Q,R,S,T odpowiadają one za polaryzacje i depolaryzacje w komorach i przedsionkach serca. Warto wiedzieć że odbiór sygnału EKG zależy od indywidualnych cech pacjenta takich jak wiek, płeć, kształt klatki piersiowej, zmian tętna, a także od stanu technicznego sprzętu pomiarowego. Diagnozy pacjenta na podstawie sygnału elektrokardiograficznego może dokonać tylko specjalista.

4.3 Zespół QRS

Elektrokardiogram jest charakterystycznym sygnałem z licznymi segmentami odpowiedzialnymi za polaryzacje i depolaryzacje w odpowiednich regionach mięśnia sercowego. Dominującym przebiegiem w sygnale EKG jest zespół QRS. Zespół QRS objawia się gwałtownym wzrostem z wychylenia Q do wychylenia R, a następnie gwałtownym spadkiem z wychylenia R do wychylenia S rys. 4.1.



Rys 4.1. Sygnał EKG z zaznaczonymi załamkami PQRST [9]

Charakterystycznymi cechami zespołu QRS jest bardzo krótki czas trwania i wysokie wychylenie, dzięki czemu zespół można sklasyfikować do szerokich widm częstotliwościowych. Kształt zespołu QRS, czas jego pojawienia się oraz interwały pomiędzy kolejnymi załamkami stanowią punkt wyjścia do oceny stanu zdrowia pacjenta. Rozpoznanie QRS pomaga także w określeniu prawidłowej pracy stymulatora u pacjentów z zamontowanymi układami stymulującymi. W badaniu EKG u osoby zdrowej czas trwania QRS powinien wynosić 0,06s do 0,11s, a wysokość (poziom) od 0,7mV do 1,8mV.

4.4 Dyskretyzacja sygnału EKG

Odebrany sygnał z urządzeń pomiarowych musi zostać odpowiednio przetworzony, aby mógł zostać odczytany przez specjalistę. Ważnym elementem przetwarzania sygnałów jest próbkowanie. Próbkowanie ma za zadanie zamienić sygnał analogowy na sygnał cyfrowy. Pod względem technicznym próbkowanie polega na zmierzeniu w określonych odstępach czasu wartości chwilowych sygnału tzw. próbek. Zgodnie z twierdzeniem Kotelnikowa-Shannona „częstotliwość próbkowania musi być co najmniej dwa razy większa od najwyższej składowej fourierowskiej próbkowanego sygnału”[28]. Przyjmuję się, że próbkowanie jest wykonywane w stałym interwale czasowym.

Jeżeli częstotliwość próbkowania jest równa częstotliwości sygnału pojawia się problem spowodowany przesunięciem w fazie taktu próbkowania i sygnału. Sygnał elektrokardiograficzny ma dużo przypadkowych zakłóceń i niejednoznaczną szerokość pasma. Dużym problemem jest także błąd kwantyzacji spowodowany rozdzielczością przetwornika. Przetworniki o dużej rozdzielczości mogą rozróżnić większą ilość stanów. Przetworniki analogowo-cyfrowe rozpoznają trzy właściwości: częstotliwość próbkowania, rozdzielczość jako stałą wartość określaną dzięki liczbie bitów i zakres napięć wejściowych. Nawet przy najlepszej częstotliwości próbkowania nie ma gwarancji zachowania ciągłości próbkowania. Do zniwelowania tzw. schodków najlepiej sprawdzają się przetworniki 8-bitowe. Niedogodnością jest również skończony czas próbkowania ($T < \infty$) co prowadzi do zawężenia częstotliwości próbkowania. Przez co nie można rozróżniać wartości próbek w odległości mniejszej niż $1/T$.

Kolejnym błędem prowadzącym do niemożności rozróżniania niskich i wysokich częstotliwości jest tzw. aliasing. Powodem tego błędu jest niewłaściwa częstotliwość próbkowania w stosunku do częstotliwości danego sygnału analogowego. Prowadzi to do błędnego odtworzenia oryginalnego sygnału. Aby sygnał został odpowiednio zdyskretyzowany częstotliwość próbkowania musi być dwukrotnie większa od najwyższej częstotliwości sygnału (z warunku Nyquista). Aliasing powoduje nakładanie się na siebie niskich i wysokich częstotliwości sygnału analogowego i tym samym zniekształca otrzymany sygnał cyfrowy.

4.5 Zakłócenia

Istnieją trzy rodzaje zakłóceń, które mają największy wpływ na odbierany sygnał EKG. Są to zakłócenia niskoczęstotliwościowe, sieciowe i zaburzenia mięśniowe. Oprócz wyżej wymienionych na sygnał elektrokardiograficzny wpływają inne niepożądane czynniki takie jak: szum urządzenia pomiarowego, błąd kwantyzacji, nierównomierne próbkowanie, szum od innych urządzeń elektrycznych oraz niestabilność linii izoelektrycznej, która prowadzi do błędnego pomiaru amplitudy załamków.

Zakłócenia niskoczęstotliwościowe są spowodowane oddechem, ruchem badanej osoby bądź poluzowaniem się elektrod. Zaburzenia mięśniowe opowiadają za pogrubienie linii zapisu lub zupełne zniekształcenie elektrokardiogramu, wynikają z pola elektrycznego i magnetycznego generowanego przez przewody zasilające i inne urządzenia elektrotechniczne. W przypadku zakłóceń mięśniowych powodem są skurcze

mięśni pochodzące od impulsów przekazywanych przez układ nerwowy. Tej kategorii zakłóceń nie da się usunąć, gdyż komórki mięśniowe są bardzo małe, a impuls ma charakter przypadkowy.

4.6 Metody redukcji zakłóceń

4.6.1 Uśrednianie sygnału

W celu redukcji zakłóceń i jak najlepszego odwzorowania sygnału EKG stosuje się różne metody, jednymi z nich jest uśrednianie

Uśrednianie w dziedzinie próbek. Metoda polega na sumowaniu próbek w sygnałach aktywacji. Sygnały pojawiające się w tych samych momentach dodawane są do tych samych komórek w elektronicznym układzie uśredniającym. Wadami tej metody są: czasochłonność, utrata informacji występujących nieregularnie, zniekształcenia niektórych fal i zmiany w zależnościach czasowych.

Uśrednianie współbieżne. Dla układów z równolegle połączonymi niskoszumowymi wzmacniaczami – k i szumach – n . Związek sygnału do szumu wynosi $\sqrt{k} * n$ oznacza to wzmocnienie sygnału względem szumu. Jednakże w sygnale EKG pojawiają się wtedy zmiany nachylenia niektórych załamek (w tym zespołu QRS) co może przyczynić się do błędnego odczytania wyniku badania elektrokardiograficznego

Uśrednianie metodą korelacji wzajemnej. W tym przypadku do uśredniania wykorzystuje się wzorzec będący fragmentem sygnału. Wzorzec jest pobierany z odpowiedniego odcinka czasowego sygnału wraz z załamekami i zespołami sygnału EKG. Następnie wzorzec jest porównywany do wszystkich cykli w sygnale.

4.6.2 Filtracja

Poza metodami uśredniania do przetworzenia sygnału wykorzystuje się, także filtrację sygnału. Popularnym filtrem jest filtr górnoprzepustowy, który przepuszcza składowe widmowe powyżej częstotliwości granicznej i jest najczęściej stosowany do redukcji zaburzeń niskoczęstotliwościowych. Do zaburzeń sieciowych wykorzystuje się filtry selektywne o wąskim bądź szerokim pasmie tłumienia. Przy zaburzeniach mięśniowych stosuje się uśrednianie ewolucji metoda wykorzystuje okresowość sygnału EKG. W przypadku losowych zakłóceń uśrednianie ewolucji prowadzi do ich zredukowania, pozostawiając niezmienny sygnał okresowy.

Popularną metodą do zminimalizowania zaburzeń mięśniowych jest również filtracja dolnoprzepustowa. Wadą tej metody jest to, że nie zawsze osiągnięte rezultaty są zadowalające. Często stosuje się także filtry wygładzające i adaptacyjne oraz przekształcenia sygnału takie jak transformata Fouriera. Przekształcenie transformatą Fouriera polega na wydzieleniu płaszczyzny czasowo-częstotliwościowej opisującej przetwarzany sygnał. Metody opierające się na filtracji charakteryzują się pewnymi ograniczeniami, które wynikają z operacji w dziedzinie czasu i w dziedzinie częstotliwości.

Drugie kryterium jest powiązane z jakością obrazu. Określa ilość bitów wymaganych do opisu poziomów szarości w zależności od przeznaczenia obrazu. Większa ilość bitów oznacza więcej informacji na obrazie. Na przykład w wizji maszynowej są wykorzystywane tylko dwa poziomy kwantyzacji (obraz binarny), ale z kolei w diagnostyce medycznej standardowa 8-bitowa rozdzielczość [9, 18, 20, 23] byłaby niewystarczająca. Stosuje się wtedy co najmniej 24-bitową rozdzielczość.

4.7 Rejestracja sygnału elektrokardiograficznego metodą Holtera

Badanie metodą Holtera polega na 24-godzinny monitorowaniu stanu elektrokardiogramu u pacjenta podczas naturalnych czynności. Obecnie ta metoda pozyskania sygnału EKG jest dużo bardziej zalecana przez kardiologów ze względu na większą ilość informacji możliwych do pozyskania z zapisu długoczasowego.

Pomiar 24-godzinny pozwala m.in. na:

- wyznaczenie zmienności rytmu serca
- rozpoznanie sekwencji arytmii
- ocenienie zmienności załamka T odpowiadającego za występowanie tachykardii komorowej i migotania komór
- dokonanie pomiaru dla pacjentów z wszczepionym rozrusznikiem serca

Elektrokardiogram mierzony metodą Holtera jest rejestrowany dzięki przenośnym odbiornikom z odprowadzeniami dwubiegunowymi. Sygnał jest zapisywany dwukanałowo lub trzykanałowo w zależności od zastosowanego sprzętu. Odbiornik rejestrujący składa się z przetworników, wbudowanej pamięci i kontrolera do kierowania

systemem. Jako zasilanie stosuje się dwie baterie R6. Skóra do pomiaru musi zostać odpowiednio przygotowana i zaleca się stosowanie elektrod o wysokiej jakości.



Rys 4.5. Przykładowy rejestrator zapisów Holtera firmy ASPEL [31]

Podczas rejestracji badany powinien zapisywać ważniejsze czynności wysiłkowe i psychiczne. Często też rejestratory są wyposażone w odpowiedni przycisk do sygnalizacji wystąpienia charakterystycznych sytuacji. Minimalna częstotliwość próbkowania z jaką powinien zostać zapisany sygnał to 120 Hz, dla rozdzielczości 8-bitowej. Rejestratory dobrej jakości zapisują sygnał z częstotliwością 500 Hz przy rozdzielczości 16 bitów co pozwala uzyskać dużo większą wiedzę o zmierzonym materiale. Po skończonym 24-godzinnym badaniu w laboratorium holterowskim przeprowadza się rozmowę z pacjentem o wystąpieniu wspomnianych wcześniej zdarzeń charakterystycznych, a zapis pamięci z odbiornika podpiną się do komputera w celu analizy.

Gdyby chcieć przełożyć zarejestrowany zapis metodą Holtera na papier to wydruk osiągnąłby długość 2160m, dlatego analiza zapisu jest niemożliwa do wykonania w sposób manualny. Programy do oceny zapisu działają podobnie do standardowego badania z 12-odprowadzeniami jednakże występuje kilka różnic. Tak długi okres rejestracji może wpływać na jakość sygnału to znaczy mogą się zdarzyć odcinki, w których jakość sygnału będzie nawet niemożliwa do odczytania. Dodatkowo zapis 24-godzinny może generować bardzo duże różnice pomiędzy wzorcami odpowiadającymi

za dane jednostki chorobowe. W związku z tym odczyt sygnału nie może zostać wykonany w pełni automatycznie ważne jest, aby wstępny fragment analizowanego zapisu został sprawdzony pod kątem poprawności przez specjalistę.

5. Detekcja podstawowych zjawisk na podstawie zapisu Holtera

5.1 Detekcja zespołu QRS

Obecnie stosuje się wiele metod elektrokardiografii komputerowej powiązanych z detekcją zespołu QRS. Zespół QRS dostarcza najwięcej informacji o pracy serca pacjenta. Systemy wykorzystywane do interpretowania sygnału EKG pozwalają na wyznaczenie min. wielkości i rytmu serca, albo wyznaczenie niektórych załamków. Jednakże pomimo wielu systemów detekcja zespołu QRS wciąż pozostaje obiektem zainteresowań naukowców. Wynika to z dużej złożoności przebiegu elektrokardiograficznego, różnorodności załamków oraz licznych szumów i zakłóceń. Powyższe kryteria nakładają bardzo wysokie wymagania na algorytmy identyfikujące zespoły QRS. Wymagana jest niezawodność, efektywność i dokładność. Poniżej zaprezentowano jedną z metod detekcji zaproponowaną przez m. in. prof. Piotra Augustyniaka [10].

Rozpoznanie zespołu QRS składa się z dwóch etapów. Pierwszy etap wiąże się z przetwarzaniem sygnału, polega na minimalizacji szumu i zakłóceń oraz podkreśleniu zespołu QRS. Wynikiem pierwszego etapu powinna być funkcja detekcyjna określająca stromość zboczy zespołu QRS.

Drugi etap wiąże się z progowaniem, które ma na celu przyporządkowanie odpowiednich punktów jako zespoły QRS. Głównym celem progowania jest wyznaczeniu lokalnego maksimum. Metoda opiera się na zidentyfikowaniu znaku pochodnej w punkcie.

Detekcja i klasyfikacja zespołu QRS opiera się na kilku grupach algorytmów poniżej kilka z nich:

1. Algorytmy w dziedzinie czasu
2. Algorytmy w dziedzinie częstotliwości
3. Algorytmy w dziedzinie czasowo-częstotliwościowej
4. Algorytmy z wykorzystaniem sztucznej inteligencji

- Sieci neuronowe
- Klasyfikatory
- Algorytmy genetyczne

5.1.1 Algorytmy identyfikacyjne stosowane w sztucznych sieciach neuronowych

Jednymi z pierwszych metod wykorzystanych w diagnostyce medycznej były jednokierunkowe wielowarstwowe sztuczne sieci neuronowe z wsteczną propagacją błędu (backpropagation - BP). Detekcji zespołu QRS za pomocą sztucznej sieci neuronowej podjęło się wielu autorów min. Xue [15,16], Hu [21], czy Morabito [13]. Wspomniani autorzy wykorzystywali właśnie wspomniany wcześniej algorytm wstecznej propagacji błędu. W literaturze można znaleźć także ulepszenia i modyfikacje algorytmu BP np. algorytm Levenberg – Marquadt [23]. Algorytm pozwala na zmniejszenie czasu uczenia.

Sieci neuronowe wyróżniają się zdolnością do klasyfikacji, dlatego też niektórzy autorzy stosują sieci neuronowe dopiero po rozpoznaniu zespołu QRS. Rozpoznanie QRS jest wtedy dokonywane za pomocą prostych metod np. za pomocą pierwszej pochodnej sygnału. Do klasyfikacji zespołu QRS wykorzystuje się perceptron wielowarstwowy (multilayer perceptron – MLP), sieci o radialnych funkcjach bazowych (radial basic functions – RBF) lub sieci z adaptacyjną teorią rezonansu (adaptive resonance theory – ART). Sieć ART opiera się na zasadzie uczenia bez nauczyciela, polega na konkurencyjnym rozpoznawaniu wprowadzonych danych. Nowo powstałe wzorce są zapisywane jeśli prawdopodobieństwo do wcześniej zapamiętanych danych jest małe. Sieci RBF charakteryzują się tym, że neurony zmieniają swoje wartości radialnie wokół tzw. centrum.


5.2 Detekcja arytmii

Arytmia jest często błędnie określana jako niewymiarowość rytmu. Do prawidłowego opisu arytmii potrzebne są sekwencje pobudeń, opisanych przez odpowiednie zespoły morfologiczne, a także interwały między załamkami RR i ilość zespołów w sekwencji. Rozpoznanie arytmii jest jedną z największych zalet zapisu holterowskiego pozwalającą wykryć współzależności pomiędzy komórkami w różnych ośrodkach serca.


Niektóre spośród rozpoznanych arytmii mogą bardzo niebezpieczne dla zdrowia i w przyszłości prowadzić nawet do zgonu pacjenta m. in. poprzez:

- utratę kontroli nad pracą serca przez układ nerwowy
- wzrost akcji serca powyżej 400/min
- spadek wydajności mechanicznej mięśnia sercowego
- niedotlenienie i w konsekwencji martwica serca

Ogólny zestaw podstawowych jednostek chorobowych związanych z arytmia możemy podzielić na arytmie komorowe i nadkomorowe. Przykładowe arytmie komorowe to bigeminia, salwa, tachykardia komorowa. Arytmie nadkomorowe to bradykardia, tachykardia nadkomorowa, częstoskurcz nadkomorowy i in.



Rys 5.2. Tachykardia komorowa [32]



Rys 5.2. Tachykardia nadkomorowa [33]

Aby rozpoznać arytmie należy znaleźć na elektrokardiogramie odpowiednią sekwencję pobudzeń ważne jest, aby początek i koniec wybranego odcinka spełniał założenia arytmii. Dzięki czemu można określić czas trwania zaburzenia. Jeśli sekwencja pobudzeń dla jednej arytmii zostaje zaburzona przez sekwencje pobudzeń przypisywaną innej arytmii oznacza to koniec jednej i początek drugiej. Ta zasada dotyczy również zespołów morfologicznych. Jeśli podczas nadkomorowego rytmu pojawi się zespół komorowy, oznacza to początek nowej arytmii.

Przy detekcji arytmii brane są pod uwagę wszystkie kanały jednocześnie, gdyż interwał między załamkami RR jak i morfologia są analizowane wspólnie. Detekcja w tym przypadku bardziej przypomina przeglądanie baz danych niż operacje na sygnałach. Problemem może być odpowiednia klasyfikacja arytmii. Arytmie w zależności od stopnia istotności dzielą się na trzy rodzaje. W związku z tym, jeśli podczas przebiegu arytmii niższego rodzaju zostanie wykryta arytmia wyższego rodzaju, trwający przebieg się kończy, ale w przypadku gdy trwa przebieg arytmii wyższych rodzajów rozpoznawanie arytmii niższego stopnia jest pomijane.

5.3. Analiza pracy kardiostymulatora

Obecne kardiostymulatory składają się z elektrody detekcyjnej i stymulacyjnej umieszczanych odpowiednio w przedsionku i komorze. Kardiostymulatory opierają się na automatyce cyfrowej pozwalającej na spersonalizowanie parametrów w zależności od nosiciela. Można je też łatwo dostroić jeśli dojdzie u chorego do upośledzenia układu bódźoprzewodzącego.

Impulsy generowane przez kardiostymulator charakteryzują się bardzo szybkim narastaniem i trwają od 0,25ms do 0,5ms. Dlatego też do zidentyfikowania impulsu kardiostymulatora przez rejestrator holterowski wymagane jest zastosowanie oddzielnego kanału rejestrującego. W pospolitych rejestratorach o częstotliwości próbkowania 120Hz impuls od kardiostymulatora jest odbierany przez przerzutnik. Wraz z rozpoczęciem próbkowania odczyt na przerzutniku jest zerowany. Dzięki czemu impulsy nie są tracone między próbkami, jednakże detekcja utrzymuje wtedy dokładność nie wykraczającą poza interwał próbkowania, wynoszący 8ms. Zaawansowane rejestratory mają wbudowany oddzielny kanał specjalnie przystosowany do odbioru impulsów kardiostymulatora, który odnotowuje przedział czasowy między impulsem, a odczytem. Pozwala to na identyfikację impulsu z dowolną dokładnością. Zaawansowane rejestratory są wyposażone w licznik zamiast przerzutnika. Licznik rozpoczyna zliczanie automatycznie od detekcji impulsu do odczytu z dokładnością np. 0,1ms. Jeśli w chwili odczytu otrzymano na liczniku zero oznacza to że impuls z kardiostymulatora się nie pojawił, każda inna wartość jest zapisywana przez kanał rejestracji odpowiadający za kardiostymulator w rejestratorze holterowskim. Po odnotowaniu impulsu wartość licznika się zeruje.

Innym zagadnieniem dla osób z wszczepionym układem stymulującym jest zidentyfikowanie pochodzenia impulsu kardiostymulatora. Aby poradzić sobie z tym problemem analizuje się kształt impulsu stymulującego. Metoda będzie użyteczna tylko wtedy gdy do przeprowadzenia analizy zastosuje się rejestrator holterowski o wysokiej częstotliwości próbkowania, a stymulator będzie generował oddzielne kształty impulsów dla komór i przedsionków

5.4. Sieci falkowo-neuronowe

Warto jeszcze wspomnieć o połączeniu przekształceń falkowych z sieciami neuronowymi do opisu sygnału elektrokardiograficznego. Metoda polega na dekompozycji przebiegu EKG na sześć poziomów z wykorzystaniem falki Symleta i Daubechies. Otrzymane w ten sposób parametry wykorzystywane są jako dane wejściowe do sieci neuronowej bez warstw ukrytych. W pracy Sternickela [18] przekształceń falkowych używa się jako wejście dla trójwarstwowej sieci neuronowej. Autor używa falek Coifleta, Daubechies oraz Haara. Falki Daubechies czwartego rzędu wykorzystuje się też do detekcji i klasyfikacji arytmii.

6. Zastosowanie sztucznej sieci neuronowej do rozpoznawania sygnałów elektrokardiograficznych

Projekt stworzony na potrzeby pracy magisterskiej został zaimplementowany w środowisku Matlab z wykorzystaniem bazy danych pochodzącej z zasobów badawczych złożonych sygnałów fizjologicznych PhysioNet.

Baza składa się ze 162 sygnałów podzielonych na trzy typy: arytmie (AR), zastoinowe niewydolność serca (ZNS) oraz normalny rytm zatokowy (NRZ). Celem będzie wytrenowanie sztucznej sieci neuronowej do rozróżnia sygnałów spośród wszystkich trzech przypadków. Na bazie 162 zapisów sygnałów składają trzy bazy danych z zasobów PhysioNet [34]:

- MIT-BIH Arrhythmia Database (96 zapisów AR)
- BIDMC Congestive Heart Failure Database (30 zapisów ZNS)
- MIT-BIH Normal Sinus Rhythm Database (36 zapisów NRZ)

Dane zapisane są w macierzy o rozmiarze 162x65536. Oznacza, to że na każdy z 162 sygnałów przypada 65536 próbek. Sygnały są pogrupowane przez etykiety w następujący sposób:

- 1:96 sygnały AR (96)
- 97:126 sygnały ZNS (30)
- 127:162 sygnały NRZ (36)

Na potrzeby projektu dane zostaną preprocesowane. Oznacza to że każdy z zapisów o ilości próbek 65536 zostanie rozbity na małe kawałki po 500 próbek. Operacja ta ma na celu zwiększenie rozmiaru bazy danych i zwiększenie jej dogodności do trenowania wielowarstwową siecią neuronową. Ponieważ najmniejsza liczba zapisów sygnałów wynosi 30 dla ZNS z każdej z dwóch pozostałych grup zostanie pobrane po 30 sygnałów. Dzięki czemu w bazie każdy sygnał zostanie reprezentowany przez tą samą liczbę zapisów.


Dodatkowo po rozbiciu zapisów na próbki. Stworzone zostaną dwie bazy w jednej będzie 50 kawałków po 500 próbek, w drugiej 100 kawałków po 500 próbek. Taki zabieg ma sprawdzić efektywność uczenia w zależności od ilości danych. Po podliczeniu w pierwszej bazie będzie 1500 zapisów dla każdej kategorii, a w drugiej 3000 dla każdej kategorii. Dla pierwszej bazy 1250 danych z każdej grupy zostanie wykorzystane do uczenia sieci, a 250 do sprawdzenia sieci. W przypadku drugiej sieci będzie to odpowiednio po 2500 i 500 danych.

6.1 Konwersja sygnałów do obrazów

Kolejnym etapem pracy na danych będzie konwersja sygnałów do postaci obrazów. Sygnały jako jednowymiarowe dane nie są stosowane na wejścia sztucznej sieci neuronowej. Z kolei obrazy jako dane dwuwymiarowe podlegają już specyfice uczenia sztucznej sieci neuronowej i można je zastosować jako dane wejściowe do sieci. Do konwersji zostanie wykorzystana ciągła transformata falkowa (ang. Continuous Wavelet Transform – CWT).

Każdy z jednowymiarowych sygnałów wraz ze swoimi wartościami zostanie uformowany dzięki ciągłej transformacie falkowej do postaci skalogramu. Każdy skalogram będzie reprezentowany przez kolorową mapę o zaimplementowanym typie jet i 128 kolorach. Następnie każdy ze skalogramów zostanie skonwertowany do postaci obrazu jpg i zapisany w folderze odpowiadającym każdej z trzech klas AR, ZNS, NRZ. Obrazy będą zapisane w rozmiarze 227x227 w kolorze RGB.


Po konwersji otrzymanych zostanie w sumie 4500 skalogramów jako baza danych dla pierwszej sieci i 9000 skalogramów jako baza danych dla drugiej sieci.



Rys 6.1. Foldery ze skalogramami

6.1.1 Parametry ciągłej transformaty falkowej

Do przekształceń z użyciem ciągłej transformaty falkowej zastosowano polecenie *cwtfilterbank* w matlabie z następującymi parametrami. SignalLength wynosi 500 zgodnie z ilością próbek. Użyto falki 'Analytic Morlet (amor)' ten rodzaj falki ma taką samą rozbieżność w dziedzinie czasu i częstotliwości. Falki analityczne charakteryzują się jednostronnym widmem i złożonymi wartościami w dziedzinie czasu. Dzięki czemu są dobrym wyborem do przeprowadzania analiz czasowo-częstotliwościowych opierających się na ciągłej transformacie falkowej. Kolejnym parametrem w składni jest 'VoicePerOctave', parametr oznacza służy do wyznaczenia liczby filtrów środkowoprzepustowych użytych w transformacie falkowej.



Rys 6.1.1.1. Przykładowy skalogram

```
function ekgtfsg(daneekg,transfalk,typekg)
    sygnaly=100;
    probki=500;
    colormap=jet(128);
    if typekg=='ARR'
        folderpath=strcat('D:\Projekt_magisterka_1\zbiordanych\ar\');
        findx=0;
        for i=1:30
            indx=0;
            for k=1:sygnaly
                ecgsignal=daneekg(i,indx+1:indx+probki);
                cfs = abs(transfalk.wt(ecgsignal));
                im = ind2rgb(im2uint8(rescale(cfs)),colormap);
                filenameindex=findx+k;
                filename=strcat(folderpath,sprintf('%d.jpg',filenameindex));
                imwrite(imresize(im,[227 227]),filename);
                indx=indx+probki;
            end
            findx=findx+sygnaly
        end
    elseif typekg=='CHF'
```

Rys 6.1.1.2. Fragment funkcji odpowiedzialnej za konwersję sygnału do obrazu

6.2 Implementacja sztucznej sieci neuronowej

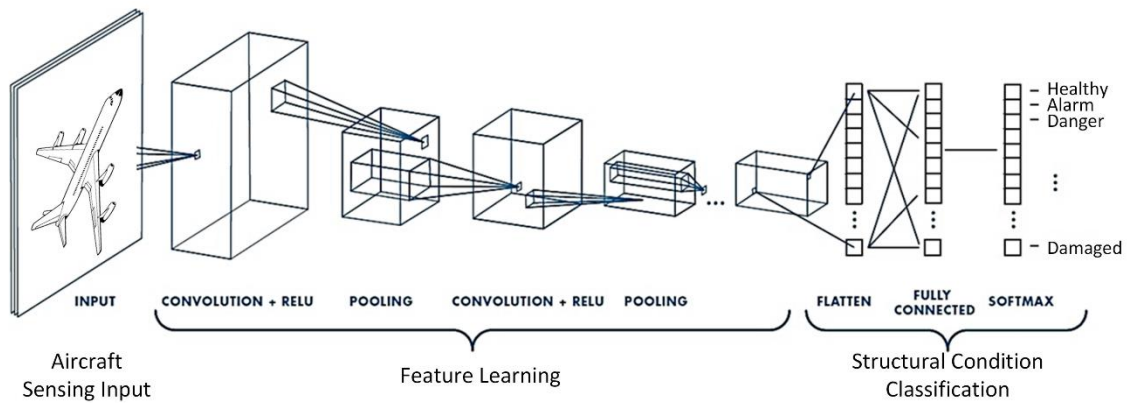
6.2.1 Sieć konwolucyjna

Siecią użytą w projekcie będzie konwolucyjna sieć neuronowa. Ten typ sieci należy do głębokich sieci neuronowych i jest predestynowany do uczenia obrazów. Sieci konwolucyjne są szczególnie użyteczne w przypadku klasyfikacji dużych obrazów o wysokiej rozdzielczości. Zwykle sieci do takiej klasyfikacji potrzebowałyby ogromnej ilości neuronów wejściowych przez co czas obliczeń takiej sieci byłby bardzo powolny. Sieci konwolucyjne z kolei nie pobierają na wejściu całego obrazu, ale jakiś jego mniejszy fragment. Polega to na „przejeżdżaniu” po obrazie filtrem (o pewnych wybranych wymiarach) i przekazaniu do sieci dokładnie tego fragmentu obrazu na, którym znajduje się w danej chwili filtr. Taki proces działania znacząco zmniejsza rozmiar sieci.

6.2.2 Struktura sieci konwolucyjnej

Przykładową strukturę sieci przedstawiono na rys. 6.2.2. Najważniejsze elementy, których składa się sieć konwolucyjna to:

- Warstwa wejściowa (Input), przekazująca rozmiar i format zapisu obrazu
- Warstwa konwolucyjna (convolution), obliczane są w niej wyjścia neuronów połączonych z poszczególnymi fragmentami obrazów. Obliczenia polegają na wyznaczeniu iloczynu skalarnego pomiędzy wagami neuronów w warstwie, a fragmentem z warstwy wejściowej. Iloczyn skalarny jest operacją, która zwraca sumę iloczynów odpowiadających sobie wartości w dwóch równych wektorach.
- Warstwa ReLU (ReLU), wykorzystuje funkcję ReLU (wynoszącą $\max(0, x)$)
- Warstwa łącząca (pooling), zachodzi w niej próbkowanie przestrzenne prowadzące do zmniejszenia rozmiaru obrazu, a przez to obniżenie ilości cech oraz stopnia zaawansowania obliczeń w sieci.
- Warstwa połączeń każdy z każdym (fully connected) przedstawia wynik klasyfikacji odpowiadając po jednym neuronie, dla każdej z wprowadzonych klas. Warstwa opiera się na uczeniu nadzorowanym i wykorzystuje zasadę połączenia każdy z każdym między neuronami z poprzedniej warstwy.



Rys 6.2.2. Przykładowa struktura sieci konwolucyjnej [43]

6.2.3 Składnia warstw w zaimplementowanej sztucznej sieci neuronowej

Sieć zastosowana w projekcie składa się z warstwy wejściowej czterech warstw konwolucyjnych oraz warstwy wyjściowej. Składnie warstw w Matlabie przedstawiono na rys. 6.2.3

```
layers=[
    imageInputLayer([227 227 3], 'Name', 'Input')

    convolution2dLayer(3, 8, 'Padding', 'same', 'Name', 'Conv_1')
    batchNormalizationLayer('Name', 'BN_1')
    reluLayer('Name', 'Relu_1')
    maxPooling2dLayer(2, 'Stride', 2, 'Name', 'MaxPool_1')

    convolution2dLayer(3, 16, 'Padding', 'same', 'Name', 'Conv_2')
    batchNormalizationLayer('Name', 'BN_2')
    reluLayer('Name', 'Relu_2')
    maxPooling2dLayer(2, 'Stride', 2, 'Name', 'MaxPool_2')

    convolution2dLayer(3, 32, 'Padding', 'same', 'Name', 'Conv_3')
    batchNormalizationLayer('Name', 'BN_3')
    reluLayer('Name', 'Relu_3')
    maxPooling2dLayer(2, 'Stride', 2, 'Name', 'MaxPool_3')

    convolution2dLayer(3, 64, 'Padding', 'same', 'Name', 'Conv_4')
    batchNormalizationLayer('Name', 'BN_4')
    reluLayer('Name', 'Relu_4')

    fullyConnectedLayer(3, 'Name', 'FC')
    softmaxLayer('Name', 'Softmax');
    classificationLayer('Name', 'Output Classifiaction');
];
```

Rys 6.2.3. Warstwy w sztucznej sieci neuronowej

- `imageInputLayer`, polecenie określające wprowadzany obraz. Obraz jest w rozmiarze 227x227, liczba 3 oznacza typ RGB z nazwą `Input`
- `convolution2dLayer`, polecenie konwolucji. Liczba 3 oznacza rozmiar filtra, a więc filtry „przechodzący” po obrazie jest w rozmiarze 3x3. Liczba 8 odnosi się do liczby filtrów, czyli odpowiada tak naprawdę za liczbę neuronów w warstwie. Z każdą kolejną warstwą liczba neuronów zostaje podwojona aż do osiągnięcia 64. ‘`Padding`’, ‘`same`’ oznacza, że obraz wyjściowy z warstwy będzie w takim samym rozmiarze jak wejściowy. ‘`Conv_1`’ to nazwa warstwy.
- `batchNormalizationLayer`, polecenie mające na celu normalizację aktywacji i gradientów, doprowadzając w ten sposób do poprawy optymalizacji i szybkości uczenia sieci.
- `reluLayer`, polecenie wykorzystujące nieliniową funkcję aktywacji (ang. Rectified Linear Unit) $\max(0, x)$ czyli jeśli otrzymano wartości ujemne z procesu konwolucji to funkcja ReLU zastępuje je zerami.
- `maxPooling2dLayer`, polecenie odpowiedzialne za pooling czyli próbkowanie zmniejszające rozmiar obrazu. Liczba 2 po nawiasie w poleceniu oznacza wymiar filtra jakim jest dokonywany pooling (`PoolSize`). Dla 2 będzie to 2x2, a więc z kwadratu z czterema liczbami jest wybierana największa. ‘`Stride`’, ‘2’ oznacza krok, albo liczbę pikseli z jaką przemieszcza się `PoolSize` w pionie i poziomie, w tym przypadku przemieszcza się o 2 w obu kierunkach. W ostatniej czwartej warstwie sieci nie użyto `maxPooling2dLayer`, gdyż liczbę czterech warstw uznano za wystarczającą do nauki sieci.

Omówione zostały wszystkie polecenia w warstwach konwolucyjnych, warstwa wyjściowa charakteryzuje się innymi typami poleceń.

- `fullyconnectedLayer`, łączy neurony z warstwą poprzednią i klasyfikuje obrazy. Liczba 3 odpowiada za liczbę neuronów wyjściowych w warstwie, a więc musi być zgodna z liczbą sygnałów do rozpoznania (AR, NRZ, ZNS)
- `softmaxLayer`, polecenie ma zadanie znormalizować wynik `fullyconnectedLayer` wykorzystując funkcję aktywacji softmax. Wynik z `softmaxLayer` zawiera wartości bezwzględne z wszystkich trzech neuronów podzielone przez sumę tych wartości. Taki

wynik jest wykorzystywany przez następne polecenie do klasyfikacji prawdopodobieństwa, dla każdej z trzech grup danych.

- `classificationLayer`, jest to ostatnie polecenie wykorzystujące prawdopodobieństwa zwracane przez funkcje aktywacji softmax dla każdego wyniku do przyporządkowania wartości wyjściowych do każdej z trzech klas oraz do obliczenia strat(niekompletnych przyporządkowani).

6.2.4 Parametry uczenia sztucznej sieci neuronowej

Sieć do uczenia wykorzystuje parametry określone przez polecenie Matlaba `trainingOptions` rys.6.2.4. Parametry są dobierane manualnie, aż do uzyskania najlepszych wyników uczenia sieci.

```
options = trainingOptions('sgdm', ...  
    'MiniBatchSize',20, ...  
    'InitialLearnRate', 0.001, ...  
    'MaxEpochs',6, ...  
    'Shuffle', 'every-epoch', ...  
    'ValidationData', TestImages, ...  
    'ValidationFrequency',20, ...  
    'Verbose', true, ...  
    'Plots', 'training-progress');
```

Rys 6.2.4. Przykładowe parametry uczenia sieci.

- `sgdm`, jest to solver użyty do uczenia sieci poza `sgdm` jest jeszcze `rmsprop` i `adam`. Wybrana metoda `sgdm` (ang. stochastic gradient with momentum) ma zabezpieczyć sieć przed gwałtownymi zmianami współczynników wagowych. Aby temu zapobiec sieci nadaje się pewną bezwładność określaną przez współczynnik `momentum`. Dzięki bezwładności zmiana wag w aktualnym cyklu jest zależna od zmiany wag w cyklach poprzednich.

- `MiniBatchSize`, jest to podzbiór zestawu uczącego używany do oceny gradientu funkcji strat i aktualizacji wag. Liczba 20 po przecinku, oznacza co ile iteracji następuje aktualizacja.


- `InitialLearnRate`, współczynnik uczenia sieci. Jeśli współczynnik jest za mały trening sieci trwa bardzo długo, jeśli współczynnik jest za wysoki wtedy sieć może osiągnąć nieoptymalny wynik lub odbiegać od niego.

- `MaxEpochs`, wyznacza maksymalną ilość epok do uczenia sieci.


- Shuffle, polecenie pozwalające na przetasowanie danych może być określone przez trzy parametry: once, never, every-epoch. Wybrany parametr every-epoch tasuje dane uczące przed każdą epoką oraz dane walidacyjne (sprawdzające) przed każdą walidacją sieci.
- ValidationData, polecenie pobierające dane walidacyjne.
- ValidationFrequency określa liczbę iteracji, po której następuje walidacja sieci.
- Verbose, parametr pozwalający wyświetlić informacje o progresie uczenia sieci w command window
- Plots, wyświetla wykres postępu uczenia sieci

6.3 Zebranie wyników sieci

Na kolejnych stronach zostaną przedstawione rysunki ze strukturą sieci i wynikami uczenia dla dwóch sieci neuronowych. Jednej opartej na bazie 4500 skalogramów i drugiej opartej na 9000 skalogramów.




Rys 6.3.1. Struktura zaimplementowanej sieci.



Rys 6.3.2. Wykres procesu uczenia dla sieci z bazą 4500 skalogramów.

Confusion Matrix				
Output Class	ar	nrz	zns	
	<div>237 31.6%</div>	<div>4 0.5%</div>	<div>4 0.5%</div>	<div>96.7% 3.3%</div>
	<div>7 0.9%</div>	<div>245 32.7%</div>	<div>2 0.3%</div>	<div>96.5% 3.5%</div>
	<div>6 0.8%</div>	<div>1 0.1%</div>	<div>244 32.5%</div>	<div>97.2% 2.8%</div>
	ar	nrz	zns	
	<div>94.8% 5.2%</div>	<div>98.0% 2.0%</div>	<div>97.6% 2.4%</div>	<div>96.8% 3.2%</div>

Rys 6.3.3. Macierz wyników dla sieci z bazą 4500 skalogramów.



Rys 6.3.4. Wykres procesu uczenia dla sieci z bazą 9000 skalogramów.

Confusion Matrix				
Output Class	ar	nrz	zns	
	<div>477 31.8%</div>	<div>14 0.9%</div>	<div>7 0.5%</div>	<div>95.8% 4.2%</div>
	<div>11 0.7%</div>	<div>484 32.3%</div>	<div>4 0.3%</div>	<div>97.0% 3.0%</div>
	<div>12 0.8%</div>	<div>2 0.1%</div>	<div>489 32.6%</div>	<div>97.2% 2.8%</div>
	ar	nrz	zns	
	<div>95.4% 4.6%</div>	<div>96.8% 3.2%</div>	<div>97.8% 2.2%</div>	<div>96.7% 3.3%</div>

Rys 6.3.5. Macierz wyników dla sieci z bazą 9000 skalogramów.

7.Wnioski

Celem niniejszej pracy magisterskiej było opracowanie sztucznej sieci neuronowej do rozpoznawania sygnałów elektrokardiograficznych. Sieć na podstawie danych wejściowych miała przyporządkowywać dane testowe do odpowiadającej grupy sygnałów. Sygnały pobrane z ogólnodostępnej bazy danych Physionet zostały najpierw podzielone na równe trzy grupy po trzydzieści sygnałów w każdej, a następnie przetworzone z wykorzystaniem ciągłej transformaty falkowej do postaci skalogramów i zapisane w formacie *jpg*. Przygotowanie danych odbyło się za pomocą skryptu, w którym określono parametry transformaty falkowej oraz funkcji, w której podzielono sygnały na kawałki po 500 próbek, a także zdefiniowano rozmiar i ilość kolorów w skalogramach. Przetworzone sygnały w postaci skalogramów zostały zapisane w trzech oddzielnych folderach. Każdy folder odpowiadał innemu z trzech typów sygnałów AR, ZNS i NRZ.

Do zaprojektowania sieci neuronowej wykorzystano sieć konwolucyjną charakterystyczną do pracy na obrazach. Sieć uczono na dwóch oddzielnych bazach danych. Pierwsza składała się z 3750 danych uczących i 750 danych testowych, druga odpowiednio z 7500 danych uczących i 1500 danych testowych. Metodą prób i błędów dobierano parametry sieci do osiągnięcia jak najlepszych rezultatów. Wyniki uczenia sieci zostały przedstawione na rys. 6.3.1 – 6.3.4. Dla obu sieci zastosowano te same najlepsze parametry rys. 6.2.3 i otrzymano niemal identyczne wyniki. Dalsze próby zmian takie jak zmiana: ilości epok, współczynnika uczenia, częstotliwości aktualizacji wag, mogą prowadzić do przeuczenia lub do spadku jakości sieci.

Podstawowe cele postawione pracy zostały spełnione. Udało się osiągnąć jakość uczenia sieci na poziomie 96,8% i 96,7%. Z pewnością istnieją metody pozwalające uzyskać lepsze rezultaty. Może to być na przykład bardziej rozbudowana sieć czy też wzbogacenie zbioru danych o inne sygnały z innych jednostek chorobowych. Niemniej jednak najważniejsze przeznaczenie sieci czyli zdolność do rozpoznawania sygnałów elektrokardiograficznych zostało spełnione.

8. Bibliografia

- [1] Tadeusiewicz R.: *Elementarne wprowadzenie do techniki sieci neuronowych z przykładowymi programami*, Akademicka Oficyna Wydawnicza PLJ, Warszawa 1998
- [2] Tadeusiewicz R.: *Wprowadzenie do sieci neuronowych*, StatSoft, Kraków 2001.
- [3] Osowski S.: *Sieci neuronowe w ujęciu algorytmicznym*, Wydawnictwo Naukowo-Techniczne, Warszawa 1996
- [4] Korbicz J., Obuchowicz A., Uciński D.: *Sztuczne Sieci Neuronowe. Podstawy i Zastosowania*, Akademicka Oficyna Wydawnicza PLJ, Warszawa 1994.
- [5] Kim P.: *MATLAB Deep Learning: With Machine Learning, Neural Networks and Artificial Intelligence*, Seoul 2017
- [6] Nowak-Brzezińska A.: *Sieci neuronowe – wprowadzenie*, <http://zsi.tech.us.edu.pl/~nowak/asi/w5.pdf>
- [7] Litwińska M.: *Zastosowanie sztucznych sieci neuronowych do analizy sygnałów elektrokardiograficznych*, http://ifmmagazine.com/wpcontent/uploads/2019/01/IFM_201503-Litwińska.pdf
- [8] Garcia T., Holtz N.: *EKG Sztuka interpretacji*, MediPage, Warszawa 2007.
- [9] http://www.robots.ox.ac.uk/~gari/papers/neuralNet_TCT.pdf
- [10] Augustyniak P.: *Przetwarzanie sygnałów elektrodiagnostycznych*, AGH Uczelniane Wydawnictwo Naukowe – Dydaktyczne, Kraków 2003.
- [11] Augustyniak P.: *Adaptacyjna dyskretna reprezentacja elektrokardiogramu*, AGH Uczelniane Wydawnictwo Naukowe – Dydaktyczne, Kraków 2003.
- [12] Dąbrowska B., Dąbrowski A.: *Elektrokardiografia holterowska*, Oxford – Polska, Wydawnictwo Medyczne, Warszawa 1994.
- [13] Morabito M., Macareta A., Taddei A., Marchesi C., *Computers in Cardiology* 1991, 23-26 September 1991, pp.181 -184.
- [14] Duraj A.: *Algorytmy rozpoznawania zespołów QRS w sygnałach elektrokardiograficznych pochodzących od pacjentów z wszczepionym układem*

stymulującym – rozprawa doktorska, Uniwersytet Zielonogórski, Wydział Elektroniki Informatyki i Telekomunikacji, Zielona Góra 2007

[15] Xue, Q., Hu Y.H., Tompkins W.J.: Artificial neural network for ECG arrhythmia monitoring, International Joint Conference on Neural Networks, 7-11 June 1992, Vol. 2, 1992, pp. 987-992.

[16] Xue, Q., Hu Y.H., Tompkins W.J.: Neural-network-based adaptive matched filtering for QRS detection, IEEE Transactions on Biomedical Engineering, Vol. 39, Issue 4, April 1992, pp. 317-329.

[17] Hamilton P.S., Soowhan H.: Classification of cardiac arrhythmias using fuzzy ARTMAP, IEEE Transactions on Biomedical Engineering, Vol. 43, Issue 4, April 1996, pp. 425-429.

[18] Sternickel K., Automatic pattern recognition in ECG time series Computer Methods and Programs in Biomedicine, Vol. 68, 2002, pp. 109-115.

[19] Momot A., Momot M., Owczarek A.: Zastosowanie transformaty falkowej w klasyfikacji sygnałów EKG, Studia Informatica, Vol, 24, No. 3 (55), 2003.

[20] Walczak F., Baranowski R.: Wskazania do 24-godzinnej rejestracji EKG u pacjenta z wszczepionym stymulatorem - zalecenia, Sekcji Elektrokardiologii Nieinwazyjnej PTK oraz aktualne stanowisko ACC/AHA. Kometarz, Folia Cardiologica, 2000; Nr 8, Supplement A, A3-A5.

[21] Hu Y.H., Tompkins W.J., Urrusti J.L., Afonso V.X., Application of Artificial Neural Networks for ECG signal detection and classification, Journal of Electrocardiology, Vol. 26, Supplement, 1993, pp. 66-73

[22] Suzuki Y., Self organizing QRS-wave recognition in ECG using neural networks, IEEE Transactions on Neural Networks, Vol. 6, Issue 6, November 1995, pp. 1469 - 1477

[23] Hagen M.T., Menhaj M.B.: Training feedforward networks with the Marquardt algorithm, IEEE Transaction on Neural networks, Vol. 5, 1994, pp. 989 – 993.

[24] <https://slideplayer.pl/slide/812905/>

[25] https://www.researchgate.net/figure/Kohonen-network-architecture_fig1_224355225

[26] http://www.neurosoft.edu.pl/media/pdf/jbartman/sztuczna_inteligencja/NTI9.pdf

- [27] <https://smp.uph.edu.pl/msn/32/ambroch.pdf>
- [28] <https://absta.pl/rozpoznawanie-choroby-parkinsona-na-podstawie-gosu-przy-wykorz-v2.html>
- [29] <http://www.wada-serca.pl/dorosli/serce2/uklad-przewodzacy-serca-2>
- [30] http://www.ratownikmed.pl/czynnosci/czynnosci_monitorowanie.html
- [31] <https://www.aspel.com.pl/holter-ekg-aspekt-712-v-301,3,22557,21763>
- [32] https://elentra.healthsci.queensu.ca/assets/modules/ECG/ventricular_tachycardia.html
- [33] https://elentra.healthsci.queensu.ca/assets/modules/ECG/supraventricular_tachycardia_av_reentry.html
- [34] https://github.com/mathworks/physionet_ECG_data/
- [35] <https://steemit.com/polish/@jacekw/rodzaje-sztucznych-sieci-neuronowych>
- [36] <https://www.mdpi.com/1424-8220/19/22/4933/htm>
- [37] <http://home.agh.edu.pl/~horzyk/lectures/ai/SztucznaInteligencja-UczenieGlebokichSieciNeuronowych.pdf>

9. Załączniki

1. Treść kodu z programu Matlab z funkcją konwersji
function ekgtfskg(daneekg,transfalk,typekg)

```
sygnaly=100;
probki=500;
colormap=jet(128);
if typekg=='ARR'
    folderpath=strcat('D:\Projekt_magisterka_1\zbiordanych\ar\');
    findx=0;
    for i=1:30
        indx=0;
        for k=1:sygnaly
            ecgsignal=daneekg(i,indx+1:indx+probki);
            cfs = abs(transfalk.wt(ecgsignal));
            im = ind2rgb(im2uint8(rescale(cfs)),colormap);
            filenameindex=findx+k;
            filename=strcat(folderpath,sprintf('%d.jpg',filenameindex));
            imwrite(imresize(im,[227 227]),filename);
            indx=indx+probki;
        end
        findx=findx+sygnaly
    end
elseif typekg== 'CHF'
    folderpath=strcat('D:\Projekt_magisterka_1\zbiordanych\zns\');
    findx=0;
    for i=1:30
        indx=0;
        for k=1:sygnaly
            ecgsignal=daneekg(i,indx+1:indx+probki);
            cfs = abs(transfalk.wt(ecgsignal));
```

```

        im = ind2rgb(im2uint8(rescale(cfs)),colormap);
        filenameindex=findx+k;
        filename=strcat(folderpath,sprintf('%d.jpg',filenameindex));
        imwrite(imresize(im,[227 227]),filename);
        indx=indx+probki;
    end
    findx=findx+sygnaly
end
elseif typekg== 'NSR'
    folderpath=strcat('D:\Projekt_magisterka_1\zbiordanych\nrz\');
    findx=0;
    for i=1:30
        indx=0;
        for k=1:sygnaly
            ecgsignal=daneekg(i,indx+1:indx+probki);
            cfs = abs(transfalk.wt(ecgsignal));
            im = ind2rgb(im2uint8(rescale(cfs)),colormap);
            filenameindex=findx+k;
            filename=strcat(folderpath,sprintf('%d.jpg',filenameindex));
            imwrite(imresize(im,[227 227]),filename);
            indx=indx+probki;
        end
        findx=findx+sygnaly
    end
end
end

```

```

2. Treść kodu z programu Matlab ze skryptem
%program do generowania skalogramow z sygnalow ekg

load('ECGData.mat'); %zaladowanie bazy danych ekg
data=ECGData.Data; %przypisanie zniennej do bazy danych
labels=ECGData.Labels; %przypisanie zniennej do etykiet sygnalow


ARR=data(1:30,:); %pobranie pierwszych 30 sygnalow
CHF=data(97:126,:);
NSR=data(127:156,:);
signallength=500;


%Definiowanie wlasnosci ciaglej transformaty falkowej
fb=cwtfiltbank('SignalLength',signallength,'Wavelet', 'amor','VoicesPerOctave',12);


%tworzenie folderow
mkdir('zbiordanych'); %folder glowny
mkdir('zbiordanych\ar'); % podfolder
mkdir('zbiordanych\zns');
mkdir('zbiordanych\nrz');


typekg={'ARR','CHF','NSR'}


%funkcje do konwertowania sygnalow do obrazow
ekgctfsg(ARR,fb,typekg{1});
ekgctfsg(CHF,fb,typekg{2});
ekgctfsg(NSR,fb,typekg{3});

```

3. Treść kodu z programu Matlab z siecią neuronową

```
clc
```

```
clear all
```

```
digitDatasetPath='D:\Projekt_magisterka_1\zbiordanych';
```

```
digitimages=imageDatastore(digitDatasetPath, 'IncludeSubfolders',  
true,'LabelSource','foldernames');
```

```
numTrainFiles=2500; %liczba danych uczących
```

```
[TrainImages,TestImages]=splitEachLabel(digitimages,numTrainFiles,'randomize');
```

```
layers=[
```

```
    imageInputLayer([227 227 3], 'Name', 'Input')
```

```
    convolution2dLayer(3, 8,'Padding', 'same','Name','Conv_1')
```

```
    batchNormalizationLayer('Name','BN_1')
```

```
    reluLayer('Name','Relu_1')
```

```
    maxPooling2dLayer(2,'Stride',2,'Name','MaxPool_1')
```

```
    convolution2dLayer(3, 16,'Padding', 'same','Name','Conv_2')
```

```
    batchNormalizationLayer('Name','BN_2')
```

```
    reluLayer('Name','Relu_2')
```

```
    maxPooling2dLayer(2,'Stride',2,'Name','MaxPool_2')
```

```
    convolution2dLayer(3, 32,'Padding', 'same','Name','Conv_3')
```

```

batchNormalizationLayer('Name','BN_3')
reluLayer('Name','Relu_3')
maxPooling2dLayer(2,'Stride',2,'Name','MaxPool_3')

convolution2dLayer(3, 64,'Padding', 'same','Name','Conv_4')
batchNormalizationLayer('Name','BN_4')
reluLayer('Name','Relu_4')

fullyConnectedLayer(3,'Name','FC')
softmaxLayer('Name','Softmax');
classificationLayer('Name','Output Classifiaction');
];
figure;
lgraph = layerGraph(layers);
plot(lgraph); %graf struktury sieci

%Parametry uczenia sieci

options = trainingOptions('sgdm', ...
    'MiniBatchSize',20, ...
    'InitialLearnRate', 0.001, ...
    'MaxEpochs',6, ...
    'Shuffle', 'every-epoch', ...
    'ValidationData', TestImages, ...
    'ValidationFrequency',20, ...
    'Verbose', true, ...
    'Plots', 'training-progress');
```



```
net= trainNetwork(TrainImages, layers, options);

YPred = classify(net,TestImages); %rozpoznawanie skalogramow
YValidation = TestImages.Labels; %pobranie etykiet danych
%wyznaczenie dokladosci przyporzadkowania
accuracy = sum(YPred == YValidation)/numel(YValidation);

%Plotting Confusion Matrix
plotconfusion(YValidation,YPred)
```